

机器学习 实验报告

实验一：基于 kNN 的手写数字识别

姓名：尚文轩

学号：2412456

专业：计算机科学与技术

实验数据集：Semeion 手写数字数据集

完成日期：2026 年 10 月 9 日

GitHub 仓库

https://github.com/ZR-1N/Machine_Learning_NKU

南开大学

目录

1	实验概述	1
1.1	实验目的	1
1.2	实验内容与进阶要求	1
2	数据集与实验环境	1
2.1	数据集说明	1
2.2	数据文件关系验证	2
2.3	实验环境	2
3	kNN 算法原理	3
3.1	基本思想	3
3.2	距离度量	3
3.3	k 值选择	3
4	自写 kNN 与 LOO 实现	4
4.1	数据读取与标签转换	4
4.2	向量化距离计算	4
4.3	多数表决与平局规则	4
4.4	留一法交叉验证	5
5	样本可视化与数据检查	6
5.1	导论示例代码运行情况	6
6	Weka 对比实验	7
6.1	ARFF 转换	7
6.2	Weka 参数设置	8
7	实验结果	9
7.1	自写程序结果	9
7.2	Weka 结果	10
7.3	自写程序与 Weka 对比	11
8	实验结果验证与分析	12
8.1	文档预期值与实际结果不一致	12
8.2	补充复核与排序敏感性	12

8.3	按类别表现分析	13
8.4	自写分类器的混淆矩阵	14
8.5	错分类样本与形态分析	17
9	踩坑记录与解决方法	18
9.1	数据准备阶段	18
9.2	代码实现阶段	18
9.3	结果验证阶段	18
9.4	Weka 对比阶段	18
10	结论	19
	参考资料	19
A	附录：本地运行输出	19

1 实验概述

1.1 实验目的

本实验围绕 Semeion 手写数字数据集实现 k 近邻分类器，并使用留一法交叉验证评估模型效果。结合课程导论文档与 kNN 课件，本实验的目标包括：

1. 理解 kNN 作为监督学习算法的基本思想，掌握距离度量、近邻数量 k 、投票规则等关键因素对分类结果的影响。
2. 使用 Python 与 NumPy 自行实现欧氏距离、多数表决和留一法交叉验证，不依赖现成分类器完成核心实验。
3. 使用 Weka 的 IBk 分类器复现实验，并比较自写程序与 Weka 的分类精度。
4. 分析实验中出现的数据格式、评估协议、默认参数和平局处理等问题，形成可复现、可解释的实验结论。

1.2 实验内容与进阶要求

基础任务要求实现自写 kNN 和 LOO 评估，并对 $k = 1, 3, 5$ 进行实验。中级要求使用 Weka 进行对照实验。进阶要求不仅记录运行结果，还需要说明思考过程、具体实现步骤和踩坑记录。因此，本报告在常规的算法原理、实现方法、实验结果之外，专门加入数据准备验证、Weka 参数对齐、预期值异常排查和误差来源分析。

2 数据集与实验环境

2.1 数据集说明

实验使用 Semeion Handwritten Digit 数据集。原始文件为 `semeion.data`，共 1593 行、266 列。每行前 256 列表示 16×16 二值手写数字图像展开后的像素，后 10 列表示 one-hot 编码标签。设原始行向量为

$$\mathbf{r} = (x_1, \dots, x_{256}, y_0, \dots, y_9),$$

其中 $x_i \in \{0, 1\}$ ，标签由

$$c = \arg \max_{j \in \{0, \dots, 9\}} y_j$$

得到。

本地检查结果显示，数据矩阵形状为 (1593, 266)，类别分布如表 1 所示。各类别样本数量接近，适合用于比较不同 k 值下的整体分类效果。

表 1: Semeion 数据集类别分布

类别	0	1	2	3	4	5	6	7	8	9
样本数	161	162	159	159	161	159	161	158	155	158

2.2 数据文件关系验证

实验文件夹中同时存在完整数据 `semeion.data` 以及两份划分文件 `semeion_train.txt`、`semeion_test.txt`。起初容易误以为训练集和测试集划分文件也应参与本实验。实际核对后可知，训练文件有 1293 行，测试文件有 300 行，二者合计 1593 行；用 NumPy 将二者拼接后按行排序，与 `semeion.data` 的行集合完全一致。因此，`train/test` 文件只是全集的一个划分版本。

由于导论文档第 5 节要求使用留一法，LOO 的定义是每次从完整数据集中留出一个样本测试，其余样本训练，所以本实验只使用 `semeion.data`。这一点直接影响实验协议：如果改用固定 `train/test` 划分，样本数量、评估方式和结果都不能与 LOO 对齐。

2.3 实验环境

表 2: 实验环境与工具

项目	配置或用途
操作系统	Windows 环境下运行 Python 与 Weka
Python 依赖	NumPy 用于矩阵运算，Matplotlib 用于图像展示
核心程序	<code>exp_1.py</code> 实现 kNN 与 LOO， <code>knn.py</code> 展示样本图像
Weka 工具	Weka Explorer 中的 <code>lazy.IBk</code> 分类器
数据转换	<code>convert_to_arff.py</code> 将空格分隔数据转换为 Weka 原生 ARFF 格式

原始运行截图显示程序在名为 `m1` 的 Python 环境中执行，但没有记录 Python 与 NumPy 的具体版本。报告修订阶段的复核环境为 Python 3.12.7、NumPy 1.26.4；该环境的结果单独列于后文，不与原始记录混用。Weka 版本未在现有截图及文本输出中标明。

数据准备的思考与步骤。首先明确评估协议，再选择输入文件，以避免将固定训练/测试划分误用于 LOO。具体步骤为：

1. 将完整数据保存在 `data/semeion.data`，使用 `np.loadtxt` 读取，并检查矩阵形状为 $(1593, 266)$ 。
2. 检查前 256 列的像素取值为 0 或 1，后 10 列为合法独热编码；每行标签区域应恰有一个 1。
3. 分离特征与标签，得到 $X \in \mathbb{R}^{1593 \times 256}$ 和 $y \in \{0, \dots, 9\}^{1593}$ ，统计类别数量。

4. 比较 train/test 拼接数据与全集的行多重集合，保留重复行的计数；确认一致后，仅将完整数据用于 LOO。

3 kNN 算法原理

3.1 基本思想

kNN 是一种直观的监督学习方法，可用于分类和回归。它没有显式的参数训练过程，而是在预测阶段计算待分类样本与训练集中所有样本的距离，选出距离最近的 k 个样本，再根据这些近邻的标签进行预测。课件中用“物以类聚，人以群分”概括了这一思想：如果一个样本在特征空间中接近某一类样本，它大概率也属于该类。

对于分类任务，kNN 的三个核心步骤为：

1. 数据准备：读入带标签数据，并将 one-hot 标签转换为整数类别。
2. 寻找近邻：计算测试样本与所有训练样本的距离，按距离升序排列。
3. 投票预测：选取前 k 个近邻，以多数表决得到预测类别。

3.2 距离度量

本实验使用欧氏距离。设样本 $\mathbf{x}_i, \mathbf{x}_j \in \mathbb{R}^{256}$ ，则二者距离为

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{m=1}^{256} (x_{im} - x_{jm})^2}.$$

Semeion 的像素为 0/1 二值特征，因此欧氏距离与汉明距离存在单调关系：平方欧氏距离实际上等于两个二值向量不同位置的数量。使用欧氏距离可以保持与导论代码、Weka 默认距离设置一致。

课件强调不同量纲的特征应归一化。本实验的全部像素具有相同取值范围 $\{0, 1\}$ ，不存在量纲较大的特征支配距离的问题，因此自写程序直接使用原始二值像素。标签只用于投票及评价，不参与距离计算。

3.3 k 值选择

k 是 kNN 的关键超参数。 k 过小时，模型容易受噪声或异常样本影响，分类边界更不稳定； k 过大时，模型会过度平滑局部结构，可能忽略细粒度差异。课件建议常用 $k = 3, 5, 7$ ，本实验按照导论文档要求比较 $k = 1, 3, 5$ 。

4 自写 kNN 与 LOO 实现

4.1 数据读取与标签转换

核心读取代码如下。前 256 列作为特征矩阵 X ，后 10 列通过 `argmax` 转换为 0 到 9 的整数标签。

Listing 1: 数据读取与标签转换

```
1 raw = np.loadtxt('data/semion.data')
2 X = raw[:, :256]
3 y = np.argmax(raw[:, 256:], axis=1)
```

4.2 向量化距离计算

LOO 需要进行 1593 轮评估。每一轮中，一个样本作为测试样本，其余 1592 个样本作为训练样本。若使用纯 Python 双重循环，需要大约

$$1593 \times 1592 \times 256 \approx 6.5 \times 10^8$$

次逐维计算，运行时间会明显增加。因此，实验中使用 NumPy 广播一次性计算测试样本到所有训练样本的距离：

Listing 2: 欧氏距离的向量化实现

```
1 def euclidean_distances(X_train, x_test):
2     squares = (X_train - x_test) ** 2
3     dists = np.sqrt(squares.sum(axis=1))
4     return dists
```

这里 $X_{\text{train}} - x_{\text{test}}$ 会自动将一维测试向量按行广播到训练矩阵上，从而得到所有训练样本与测试样本的逐维差值。该实现简洁且高效，是本实验完成 LOO 的关键。

4.3 多数表决与平局规则

预测阶段先对距离排序，取前 k 个近邻标签，再使用 `np.bincount().argmax()` 得到票数最多的类别：

Listing 3: kNN 预测函数

```
1 def knn_predict(X_train, y_train, x_test, k):
2     dists = euclidean_distances(X_train, x_test)
3     k_idx = np.argsort(dists)[:k]
4     k_labels = y_train[k_idx]
5     pred = np.bincount(k_labels).argmax()
```

```
6 return pred
```

需要注意的是，`argmax()` 在多个类别票数相同时返回编号最小的类别。这是一个确定性的平局规则，但不一定与 Weka 完全相同。对于二值像素数据，距离并列很常见，平局规则会在 $k = 3$ 等情况下造成小幅结果差异。

导论允许在投票平局时随机选取类别，本实现采用编号最小者，便于固定投票结果。奇数 k 并不能保证多分类任务没有平局，例如 $k = 3$ 时三个邻居分别属于不同类别，仍会出现 1-1-1 的票数并列。此外，`np.argsort` 默认排序不保证等距离样本的相对顺序，因此投票规则固定并不等于近邻集合跨环境完全固定。

4.4 留一法交叉验证

LOO 的实现如下。每轮删除第 i 个样本作为测试样本，其余样本用于预测，最后统计正确率。

Listing 4: LOO 评估函数

```
1 def loo_eval(X, y, k):
2     n = X.shape[0]
3     correct = 0
4     for i in range(n):
5         x_test = X[i]
6         X_train = np.delete(X, i, axis=0)
7         y_train = np.delete(y, i)
8         pred = knn_predict(X_train, y_train, x_test, k)
9         if pred == y[i]:
10             correct += 1
11     return correct / n
```

评估指标与数据隔离。设第 i 轮预测为 $\hat{y}_i$ ，则

$$\text{Acc}_{\text{LOO}} = \frac{1}{1593} \sum_{i=1}^{1593} \mathbf{1}(\hat{y}_i = y_i).$$

每个样本恰好被测试一次，且在对应轮次中不属于训练集。若不删除测试样本，样本自身会以零距离参与近邻搜索，导致评估失真。LOO 衡量逐样本留出的识别效果；数据没有在本实验中按书写者划分，因此结果不能直接解释为对全新书写者的识别性能。

实现思路与执行步骤。采用三个函数分别负责距离计算、投票预测和评估，以便检查错误来自哪个环节。

1. 编写距离函数，用广播完成逐维相减，沿特征轴求和，返回长度为 1592 的距离向量。
2. 编写预测函数，对距离排序，选取前 k 个下标，统计对应标签并输出多数类别。

3. 编写 LOO 函数，按同一下标同时删除特征行和标签，防止训练数据与标签错位。
4. 对 $k = 1, 3, 5$ 分别遍历全集，统计预测正确次数，以总样本数为分母计算准确率。
5. 在项目根目录运行 `python exp_1.py`，保存控制台输出并截图，核对样本数量与三个 k 值。

主流程与结果输出如下：

Listing 5: 不同 k 值的评估主流程

```
1 if __name__ == '__main__':  
2     for k in [1, 3, 5]:  
3         acc = loo_eval(X, y, k)  
4         print(f'k={k} LOO accuracy = {acc:.4f}')
```

上例仅将输出文字写为英文，评估调用与源码一致。距离计算总量为 $O(n^2d)$ ，逐轮完整排序还需要 $O(n^2 \log n)$ 的工作量，其中 $n = 1593$ 、 $d = 256$ 。向量化减少 Python 层面的循环开销，并未改变距离计算的渐近复杂度。当前实现每轮还通过 `np.delete` 复制训练数据；规模进一步扩大时，可考虑距离缓存或批量计算，并明确距离并列的处理规则。

5 样本可视化与数据检查

5.1 导论示例代码运行情况

导论文档给出的样本展示代码注释写的是“随机画 6 张图”，但原代码使用 `for i in range(6)` 取固定前 6 行。实际文件中前 20 个样本的标签均为 0，因此每次展示的前 6 张图都标为 0。数字 0 的总样本数为 161，这不表示前 161 行全部属于数字 0。图 1 展示了固定取样现象。



图 1: 导论示例代码运行结果: 固定展示前 6 个样本

逐行检查表明, 前 6 个像素向量彼此不同, 属于六个不同样本; 现有数据没有提供可供本实验核查的书写者标识, 不能据此断定来自六位不同书写者。若希望真正随机展示样本, 可采用以下修正写法。本报告截图仍为原始示例的固定取样结果。

Listing 6: 随机抽样展示 6 张图像的修正写法

```

1 idx = np.random.choice(len(X), 6, replace=False)
2 for pos, i in enumerate(idx):
3     plt.subplot(2, 3, pos + 1)
4     plt.imshow(X[i].reshape(16, 16), cmap='gray')
5     plt.title(y[i])
6     plt.axis('off')

```

可视化的思考与步骤。展示图像用于检查像素排列和标签解码, 而不能替代对全部数据的合法性检查。执行时先运行 `python knn.py`, 确认控制台显示 1593 个样本、256 个像素; 再将选中的 256 维向量恢复为 16×16 , 使用统一灰度色图并以真实标签作为标题, 保存截图。随机展示时可固定随机种子以便复现, 但该抽样只改变展示内容, 不改变 LOO 输入数据及评估结果。

6 Weka 对比实验

6.1 ARFF 转换

Weka 不能直接将 `semion.names` 当作数据文件读取。`.names` 文件只是数据集说明, Weka 会按 C4.5 的属性定义文件解析, 因而报出格式错误。同时, 原始 `semion.data`

是空格分隔文本，也不是 Weka 最稳定的输入格式。为保证 Weka 正确识别属性和类别，本实验使用脚本转换为 ARFF：

Listing 7: ARFF 转换的关键结构

```
1 lines.append('@relation semeion_handwritten_digit')
2 for i in range(256):
3     lines.append(f'@attribute p{i+1} numeric')
4 lines.append('@attribute class {0,1,2,3,4,5,6,7,8,9}')
5 lines.append('@data')
6 for row, label in zip(X, y):
7     pixels = ','.join(str(int(v)) for v in row)
8     lines.append(pixels + f',{int(label)}')
9 with open('data/semeion.arff', 'w', encoding='utf-8') as f:
10     f.write('\n'.join(lines))
```

其中 256 个像素属性声明为 `numeric`，类别属性声明为 `nominal` 类型 `{0,1,2,3,4,5,6,7,8,9}`。若类别也被当成 `numeric`，Weka 可能无法按分类任务正确处理。

6.2 Weka 参数设置

Weka Explorer 中选择 `lazy.IBk`。为了与自写代码可比，设置如下：

- KNN 分别设为 1、3、5。
- `DistanceFunction` 使用 `EuclideanDistance`。
- `distanceWeighting` 设置为 `No distance weighting`；记录的命令行没有启用 `-I` 或 `-F` 加权选项。
- `windowSize` 为 0，即不限制训练池大小，对应 `-W 0`。该参数与距离加权无关。
- 不启用 `IBk` 内部自动选择 k 的 `crossValidate` 选项，以保持每次运行指定的 k 值。
- `Cross-validation folds` 设置为 1593，使每折只留出一个样本，等价于 LOO。

根据 Weka 的 `IBk` 官方参数说明，`-I` 表示按距离倒数加权，`-F` 表示按 $1 - d$ 加权，`-W` 表示训练池窗口大小。实验应核对实际配置，不将距离倒数加权视为必然的默认设置。若启用加权投票，就与自写程序的等权投票不同。`IBk` 内部选择 k 的交叉验证和 Explorer 的外部性能评估也属于不同设置。

对比实验的思考与操作步骤。对比的前提是使用相同样本、特征、类别定义及外部评估协议，而不仅是设置相同 k 。


1. 在项目根目录运行 `python convert_to_arff.py`，生成 `data/semeion.arff`。

2. 打开 Weka Explorer, 在 Preprocess 页通过 Open file 导入 ARFF, 检查 Instances 为 1593、Attributes 为 257, 并将最后一列 nominal 属性 `class` 设为目标类别。
3. 在 Classify 页选择 `lazy.IBk`, 将 KNN 设为 1, 检查距离函数、投票方式及窗口设置。
4. 在 Test options 中选择 Cross-validation, 将 Folds 设为 1593, 然后 Start; 检查输出 Test mode 为 1593-fold cross-validation。
5. 记录正确/错误分类数、准确率和混淆矩阵, 将输出保存为文本并截图; 分别设置 KNN 为 3、5 后重复运行。
6. 对照每次输出内部的 Scheme 或所选结果记录识别对应的 k , 再填写比较表。截图顶部显示的是当前待运行配置, 未必是当前选中的历史结果配置。

7 实验结果

7.1 自写程序结果

原始本地运行截图如图 2 所示, 与 `loo.txt` 中的记录一致。表 3 据此整理, 保留输出的四位小数。



```

(ml) PS E:\browser\machine_learning\Lab1> python exp_1.py
样本数: 1593 | 特征数(像素): 256 | 前10个标签: [0 0 0 0 0 0 0 0 0 0]
k=1 LOO 准确率 = 0.9190
k=3 LOO 准确率 = 0.9046
k=5 LOO 准确率 = 0.9046
  
```

图 2: 自写程序的原始本地 LOO 运行结果

表 3: 自写 kNN 在 LOO 下的准确率

k	LOO 准确率	正确率百分比
1	0.9190	91.90%
3	0.9046	90.46%
5	0.9046	90.46%

结果显示, $k = 1$ 在本实现中表现最好。随着 k 从 1 增至 3 或 5, 准确率下降约 1.44 个百分点, 说明在该数据集和欧氏距离设置下, 较小的局部邻域更能保留手写数字图像的细节差异。

7.2 Weka 结果

Weka 对 $k = 1, 3, 5$ 的结果分别如图 3、图 4、图 5 所示。




图 3: Weka IBk 在 $k = 1$ 时的 LOO 结果




图 4: Weka IBk 在 $k = 3$ 时的 LOO 结果




图 5: Weka IBk 在 $k = 5$ 时的 LOO 结果

Weka 文本输出中的核心指标如表 4 所示。

表 4: Weka IBk 的 LOO 准确率

k	正确分类数	错误分类数	准确率
1	1460	133	91.6510%
3	1437	156	90.2072%
5	1445	148	90.7094%

7.3 自写程序与 Weka 对比

表 5: 自写 kNN 与 Weka IBk 结果对比

k	自写 LOO 精度	Weka LOO 精度	差异（百分点）
1	91.90%	91.6510%	0.2490
3	90.46%	90.2072%	0.2528
5	90.46%	90.7094%	0.2494

按显示精度计算，三组结果的绝对差异均小于 0.5 个百分点，未触发导论中“差异超过阈值时说明原因”的条件。差异仍可能与两类实现细节有关：一是二值像素存在等距离样本，近邻集合在边界处可能不同；二是投票平局规则可能不同。准确率接近支持整体结果的一致性，但没有 Weka 的逐样本预测和近邻记录，不能将这些可能解释认定为已经确定的原因。

8 实验结果验证与分析

8.1 文档预期值与实际结果不一致

导论文档给出的预期输出约为 98.5%，而本实验在 LOO、欧氏距离和多数表决设置下得到约 91% 的准确率。为分析差异来源，从实现逻辑、数据完整性、工具配置和评估协议四个方面进行核查。

排查过程如下：

1. 验证代码：检查欧氏距离、标签索引、测试样本排除及准确率分母。实验者另报告曾使用 scikit-learn 进行独立验证， $k = 1$ 约为 0.917；该验证的源码、版本和完整输出未包含在现有材料中，因此作为辅助说明，不作为本报告表格的数值依据。
2. 验证数据：本地计算 semeion.data 的 MD5 为 cb545d371d2ce14ec121470795a77432，并确认 train/test 合并后与全集一致。
3. 验证工具：Weka 使用 ARFF 输入、欧氏距离、无距离加权、1593 折交叉验证，得到与自写程序小于 0.5% 的差异。
4. 验证协议：依据文本输出核对 Weka 为 1593 折评估，依据源码确认自写程序每轮留出一行。现有材料没有包含其他距离和评估方式的完整实验记录，因此不将“所有变体均无法达到预期值”作为已验证结论。

上述核查表明，自写程序与 Weka 的结果一致性较高，导论文档中的预期值未能在当前数据及实验协议下复现。现有证据尚不足以确定该预期值的来源，因此本报告以本地运行记录和 Weka 输出为依据，报告实测结果。

8.2 补充复核与排序敏感性

在 Python 3.12.7、NumPy 1.26.4 环境下直接执行现有 exp_1.py，得到 0.9159、0.9065、0.9052，与原始截图有所不同。为进一步检查近邻排序的影响，保持数据、欧氏距离、LOO 与投票规则不变，仅将 `np.argsort(dists)` 替换为 `np.argsort(dists, kind='stable')` 进行补充复核，结果如表 6。该复核不修改提交源码，也不替代原始实验记录。

表 6: 修订阶段不同距离排序规则的复核结果

k	默认排序正确数	准确率	稳定排序正确数	准确率
1	1459	91.5882%	1461	91.7137%
3	1444	90.6466%	1440	90.3955%
5	1442	90.5210%	1440	90.3955%

在当前默认排序中，第 k 与第 $k + 1$ 个邻居等距的测试样本数分别为 134、342、430；多数投票出现多个最高票类别的样本数分别为 0、45、45。排序切换确实改变了正确分类数，证明近邻边界的距离并列会影响当前数据的结果。NumPy 官方文档指出，默认排序不保证等值元素的相对顺序；稳定排序则保留其原始顺序。稳定排序使近邻选择规则更明确，但仍依赖输入行顺序，不保证获得更高精度。

本次复核与原始记录之间的差异不能仅凭上述检查完全归因，因为原始运行环境的依赖版本及当时源码快照未完整保存。后续复现实验应同时记录 Python/NumPy 版本、数据校验值、源码版本、距离并列与投票平局规则。原始实验与当前复核均得到约 90%–92% 的准确率，但应明确区分两个运行批次。

补充复核脚本保存在 `report/reproduce_checks.py`。在项目根目录用 Python 执行该脚本后，将生成 `report/reproduction_checks.json`，记录环境版本、数据校验值、正确数及两种平局计数。统计逻辑保持原始默认排序预测不变，分别检查近邻边界和最高票类别是否并列。关键代码如下：

Listing 8: 等距离边界与投票平局的检查方法

```
1 order = np.argsort(dists)
2 boundary_tie = dists[order[k - 1]] == dists[order[k]]
3 counts = np.bincount(y_train[order[:k]], minlength=10)
4 vote_tie = np.count_nonzero(counts == counts.max()) > 1
5 stable_order = np.argsort(dists, kind='stable')
6 stable_pred = np.bincount(y_train[stable_order[:k]]).argmax()
```

8.3 按类别表现分析

以 Weka 的 $k = 1$ 结果为例，数字 0、1、2、3、4、5、6、7 的召回率均超过 0.91，其中数字 0 的精确率与召回率均为 0.975。数字 8 和 9 的召回率相对较低，分别为 0.806 和 0.791。结合混淆矩阵，数字 8 容易被分到 2、3、6、9 等类别，数字 9 容易被分到 3、5 等类别。这与手写数字形状相似性一致：8 的上下环结构在低分辨率二值化后可能与 2 或 6 混淆，9 的闭环和尾部也容易与 3 或 5 混淆。

$k = 3$ 与 $k = 5$ 时，整体准确率低于 $k = 1$ ，且数字 9 的召回率下降较明显。这说明扩大邻域后，一些局部写法差异被周围不同类别样本“稀释”，尤其影响形状边界较接近的类别。

8.4 自写分类器的混淆矩阵

为将总体精度与具体误分类联系起来，在 Python 3.12.7、NumPy 1.26.4 环境下对 $k = 1, 3, 5$ 分别执行完整留一法预测。绘图脚本直接调用 `exp_1.py` 的 `knn_predict` 函数，并逐轮排除测试样本，保持原程序的距离计算、默认排序和投票规则不变。三个矩阵均来自同一环境下的补充复核运行，与前述复核正确数一致，不对应原始截图或 Weka 的预测记录。错分类样例仍取本批次 $k = 1$ 的预测。

设混淆矩阵为 C ，其中 C_{ab} 表示真实类别为 a 、预测类别为 b 的样本数。矩阵行对应真实类别，列对应预测类别；对角线为正确分类，非对角线为误分类。图 6、图 7 和图 8 均显示样本计数，色阶统一为 0–160；矩阵元素总和均为 1593，对角线之和依次为 1459、1444、1442。




图 6: 自写 kNN 的 $k = 1$ LOO 混淆矩阵：补充复核运行，行是真实类别、列是预测类别

数字 8 和 9 的召回率分别为 $125/155 = 80.6452\%$ 和 $125/158 = 79.1139\%$ ，低于其他类别。最大非对角项为 $8 \rightarrow 2$ （15 次），其次为 $9 \rightarrow 3$ （14 次）和 $4 \rightarrow 1$ （11 次）。这些计数说明总体错误集中于若干相近类别，也与 Weka 的主要混淆趋势一致；不过两套实现的矩阵不是完全相同的预测记录。

$k = 3$ 的混淆矩阵。本次正确分类 1444 个、错误分类 149 个，准确率为 90.6466%。图 7 展示各类别的具体去向。




图 7: 自写 kNN 的 $k = 3$ LOO 混淆矩阵: 补充复核运行, 行是真实类别、列是预测类别

相较 $k = 1$, 数字 0、1、2、3、4、5、6 的正确分类数有所增加, 但数字 7、8、9 的正确数分别由 147、125、125 降为 136、120、114。其中 $7 \rightarrow 1$ 的错误由 9 次增至 19 次, $9 \rightarrow 5$ 由 8 次增至 12 次, $8 \rightarrow 2$ 仍为 15 次。这表明增加邻居数量带来的改善并不均匀: 部分类型受益于投票, 而易混淆类型的损失使总体精度下降。

$k = 5$ 的混淆矩阵。本次正确分类 1442 个、错误分类 151 个，准确率为 90.5210%。图 8 与另外两图使用相同轴定义和色阶。




图 8: 自写 kNN 的 $k = 5$ LOO 混淆矩阵: 补充复核运行, 行是真实类别、列是预测类别

表 7: 同一补充运行中不同 k 的整体精度及易混淆类别召回率

k	准确率	数字 7 召回率	数字 8 召回率	数字 9 召回率
1	91.5882%	93.0379%	80.6452%	79.1139%
3	90.6466%	86.0759%	77.4194%	72.1519%
5	90.5210%	86.0759%	78.0645%	70.2532%

$k = 5$ 时, 数字 8 的正确数比 $k = 3$ 多 1 个, 但数字 9 少 3 个, 且 $9 \rightarrow 3$ 增至 17 次、 $7 \rightarrow 1$ 增至 20 次。结合表 7, 较大的 k 未改善这些类别的整体识别。三个矩阵说明了精度下降集中在哪些类别, 尚不能单凭计数判定每个错误的笔画或近邻成因。

8.5 错分类样本与形态分析

图 9 展示同次运行中的 6 个错分类样本。选取方式为：将非对角混淆类型按次数降序排列，次数相同按真实类别和预测类别升序排列；对前六种类型各取原始行号最小的错误样本。该方式可复现且覆盖主要错误类型，但不是随机抽样，也不代表全部错误的形态分布。图中的 Sample 编号为 `semeion.data` 从 1 开始计数的原始行号。




图 9: 自写 kNN 在补充复核运行中的错分类样本: True 为真实标签, Predicted 为预测标签

表 8: 展示样本所属的主要混淆类型及出现次数

原始行号	真实类别	预测类别	该类型错误总数
163	8	2	15
196	9	3	14
83	4	1	11
146	7	1	9
181	9	5	8
514	5	6	6

这些图像可见环状结构、横向笔画及斜向主笔画的写法差异。在 16×16 二值表示中, 环的闭合程度和少量像素变化可能改变不同数字之间的距离。逐像素欧氏距离也未显式建模笔画结构或平移不变性, 因此形态近似可能影响近邻选择。这是基于图像的可能解释, 尚不能单独证明各样本的具体误分类原因; 进一步分析需展示其选中的近邻或做特征对照实验。

生成脚本为 `report/generate_error_figures.py`，在项目根目录用 Python 运行即可生成三个混淆矩阵和一张 $k = 1$ 错样本图，同时保存每个 k 的逐样本预测 CSV、混淆矩阵 CSV 及 `report/error_figure_summary.json`。文件名中的 $k1$ 、 $k3$ 、 $k5$ 标明对应参数。程序逐组检查矩阵总和、各行类别数量及正确数，并确认所有展示样本确实预测错误，避免图像与统计结果来自不同批次。

9 踩坑记录与解决方法

9.1 数据准备阶段

坑 1：分不清三个数据文件的关系。文件夹中同时出现完整数据和 `train/test` 划分文件，容易误用固定划分进行实验。解决方法是用 NumPy 逐行比对确认 `train/test` 合并后等于全集，并根据 LOO 要求只使用 `semeion.data`。

坑 2：注释写“随机画 6 张”，实际永远画前 6 张。原示例使用 `range(6)`，文件开头的样本标签均为 0，因此重复运行显示的类别不变。解决方法是随机抽取下标。进一步核查确认数字 0 总计 161 个、文件开头连续为 0 的样本为 20 个，不能把类别总数当作连续排列长度。

9.2 代码实现阶段

坑 3：LOO 性能问题。1593 轮 LOO 每轮都要计算 1592 个训练样本到测试样本的 256 维距离，纯 Python 双重循环会较慢。解决方法是使用 NumPy 广播向量化距离计算，使每轮的距离计算由底层数组运算完成。

9.3 结果验证阶段

坑 4：输出与文档“预期结果”不符。自写程序得到约 91% 的准确率，而导论文档预期约 98.5%。解决方法是从代码、数据、工具和实验协议四个层面核查。已有结果支持约 91% 的实测水平，但无法确定预期值的来源；不据此调整数据或评估协议。

9.4 Weka 对比阶段

坑 5：用 Weka 打开 `semeion.names` 报错。`.names` 是说明文档，不是数据文件；Weka 会按 C4.5 格式解析，失败是正常的。解决方法是将 `semeion.data` 转换为 ARFF。

坑 6：混淆距离加权与训练池窗口参数。距离加权会改变投票规则，应核对 `distanceWeighting = No distance weighting`；而 `-W 0` 只表示训练池大小不受窗口限制。外部 LOO 应通过 Explorer 的 Cross-validation 设置 1593 折实现，不通过 IBk 内部自动选择 k 的选项实现。

坑 7: Weka 与原始自写结果仍有约 0.25 个百分点差异。差异低于导论阈值,可能与距离并列及投票平局有关。补充复核证实排序规则能影响精度,但尚未将 Weka 的逐样本误差归因到具体规则。经验是同时保存实验配置和逐样本预测,避免只凭总体精度判断差异来源。

10 结论

本实验完成了基于 kNN 的 Semeion 手写数字识别任务。通过自写 Python 程序,在完整数据集上使用留一法得到 $k = 1$ 、 $k = 3$ 、 $k = 5$ 的准确率分别为 91.90%、90.46%、90.46%。Weka IBk 在相同协议下得到 91.6510%、90.2072%、90.7094%,与自写实现差异均小于 0.5%。

实验结果表明,在该数据集及当前评估设置下 $k = 1$ 的表现最好,扩大邻域并未提升分类准确率。默认参数、数据格式和评估协议均会影响结果比较,因此需统一实验设置,并结合运行记录核查结果。

修订阶段的环境复核得到略有差异的数值,并通过排序对照确认等距离邻居处理具有影响。该补充实验提高了对复现条件的认识,但不能替代对原始环境的完整记录。 $k = 1$ 是本次比较中的最优值;若进一步据此选择模型,应使用独立测试集或嵌套验证评价所选模型,避免将同一组用于选参的结果直接作为最终泛化估计。

参考资料

- [1] UCI Machine Learning Repository. Semeion Handwritten Digit Data Set. <http://archive.ics.uci.edu/ml/datasets/Semeion+Handwritten+Digit>
- [2] 课程材料:《机器学习》课程实验一导论,基于 kNN 的手写数字识别实验。
- [3] 课程材料: KNN 算法基础概念课件。
- [4] Weka Explorer 输出结果: IBk 分类器, $k = 1, 3, 5$, 1593-fold cross-validation。
- [5] Weka. IBk API Documentation. <https://weka.sourceforge.io/doc.stable/weka/classifiers/lazy/IBk.html>
- [6] NumPy. numpy.argsort Documentation. <https://numpy.org/doc/1.26/reference/generated/numpy.argsort.html>

A 附录: 本地运行输出

```
(ml) PS E:\browser\machine_learning\Lab1> python exp_1.py
样本数: 1593 | 特征数(像素): 256 | 前10个标签: [0 0 0 0 0 0 0 0 0 0]
```

k=1	L00	准确率	=	0.9190
k=3	L00	准确率	=	0.9046
k=5	L00	准确率	=	0.9046