

南開大學

实验报告

机器学习实验二回归分析

姓名：尚文轩

学号：2412456

专业：计算机科学与技术

2026 年 10 月 24 日

目录

1 摘要 **3**

2 实验概述 **3**

2.1 实验目的 3

2.2 实验内容与研究方法 3

2.3 实验流程与主要结果 4

3 数据集实验环境与评价协议 **4**

3.1 一元回归数据集 4

3.2 白葡萄酒质量数据集 4

3.3 数据预处理与重复样本检查 5

3.4 实验环境与程序组织 5

3.5 训练验证与测试划分 5

3.6 标准化与误差指标 6

4 基础实验：线性回归的参数估计 **6**

4.1 任务 1：一元线性回归与最小二乘法 6

4.2 任务 2：多元线性回归与批量梯度下降 9

5 中级实验：学习率与收敛性分析 **12**

5.1 对照实验设计 12

5.2 学习率曲线与数值结果 13

5.3 学习率收敛条件的理论分析 14

5.4 分析与解释：学习率过小对收敛的影响 14

5.5 分析与解释：学习率过大对收敛的影响 14

5.6 分析与解释：最佳学习率及其适用范围 14

6 高级实验：岭回归与正则化分析 **15**

6.1 目标函数与参数估计 15

6.2 闭式解实现与主实验设置 15

6.3 选做实验：不同正则化参数对权重与测试误差的影响 15

6.4 正则化与矩阵条件数 17

7 拓展实验：多项式回归与模型选择 **17**

7.1 多变量建模与单变量可视化 17

7.2 多项式特征与参数规模 17

7.3 训练步骤标准化与 SVD 求解 18

7.4 不同阶数的训练验证与测试结果 19

7.5 单特征散点与 1 阶 2 阶 4 阶拟合曲线 19

7.6 多变量模型的条件切片 20
7.7 分析与解释：哪个阶数的拟合效果最好 21
7.8 高阶模型误差尾部的进一步诊断 21
7.9 分析与解释：阶数过高时的过拟合现象 22

8 结果验证与综合讨论 **23**
8.1 独立求解路径的复核 23
8.2 算法实现的数值验证 23
8.3 优化误差与泛化误差的区别 24
8.4 不同模型的综合结果 24

9 实现细节与误差控制 **24**
9.1 数据读取与预处理的一致性 24
9.2 数值求解与目标函数的一致性 24
9.3 模型选择与评价指标的解释 25

10 结论 **25**

参考资料 **25**

A 运行方法与结果文件 **26**
A.1 依赖包与运行方法 26
A.2 主要输出文件与读取顺序 26

B 关键实测数值摘录 **26**
B.1 一元回归与线性模型 26
B.2 多项式与数值核验 27

1 摘要

本实验采用一元回归与白葡萄酒质量数据，实现最小二乘估计、批量梯度下降、岭回归及多项式回归，考察求解精度、学习率、正则化和模型复杂度的影响。在固定训练测试划分下，批量梯度下降迭代 3000 轮后的测试均方误差为 0.569501，接近解析解；标准测试决定系数为 0.265402。学习率的稳定上界约为 0.310016，与发散现象相符。多项式模型的训练误差随阶数增加而降低，四阶测试误差却增至 421.428415，显示明显过拟合。通过独立数值路径和误差分布复核，区分了优化误差、模型选择波动及高阶模型的预测不稳定性。

关键词：线性回归；梯度下降；岭回归；多项式回归；模型选择

2 实验概述

2.1 实验目的

本实验以一元回归数据和白葡萄酒质量数据为研究对象，实现最小二乘线性回归、批量梯度下降和岭回归，考察优化参数、正则化强度及模型复杂度对预测误差的影响。研究内容包括：

1. 理解最小二乘目标与正规方程之间的关系，能够说明矩阵不可逆或病态时的处理方法。
2. 推导并实现线性回归的批量梯度下降，记录每轮参数更新之后的训练均方误差，比较迭代解与闭式解的一致性。
3. 在固定数据划分、初始化和迭代预算下比较学习率，区分收敛缓慢、稳定收敛和数值发散。
4. 理解岭回归如何通过惩罚权重改变解，考察不同正则化参数对拟合误差和参数范数的影响。
5. 将线性模型扩展为含交互项的多项式回归，结合训练、验证及测试误差解释模型选择、欠拟合与过拟合。
6. 保存原始指标、逐轮损失、模型参数和预测值，形成能够复现并能追查异常结果的实验记录。

2.2 实验内容与研究方法

实验依次研究线性回归的参数估计、梯度下降的收敛性质、岭惩罚的作用以及多项式模型的泛化性能。各组实验采用统一的数据划分与误差指标，通过控制变量比较求解方法及模型设定的影响。主要实验内容见表1。

表 1：实验内容与比较方法

实验阶段	研究内容	比较方法
基础实验	最小二乘估计	正规方程求解；一元回归拟合与新样本预测；训练和测试 MSE。
	迭代求解	批量梯度下降；逐轮损失记录；迭代解与解析解的数值比较。
中级实验	收敛性分析	比较 6 种学习率下的损失曲线、收敛轮数与稳定性。
高级实验	正则化分析	岭回归闭式解；比较 8 种正则化参数下的误差与权重范数。
拓展实验	模型复杂度	比较 1、2、3、4 阶多项式的训练、验证及测试误差，分析误差分布。

2.3 实验流程与主要结果

实验首先核对输入数据与任务要求，再固定划分和评价指标，然后分别运行不同模型。模型选择在训练集内部完成，最终测试集用于结果比较。核心训练算法只使用 NumPy 实现，pandas 用于读写表格，Matplotlib 用于绘图，数据处理与核心算法未调用机器学习库。

本次运行中，一元回归得到 $\hat{y} = 2.520868x + 6.719009$；葡萄酒 BGD 的测试 MSE 为 0.569501，与闭式解接近。学习率候选中，0.3 达到指定训练损失阈值最快，1.0 发散。岭回归没有优于普通最小二乘基线。二阶多项式在内部验证集最优，但最终测试 MSE 高于一阶；四阶模型则产生显著的尾部大误差。这些现象说明优化收敛、训练拟合能力和样本外泛化能力需要分别判断。

3 数据集实验环境与评价协议

3.1 一元回归数据集

一元回归实验使用课程“代码模版”目录下的 `data/dataset_regression.csv`。数据共有 120 行、两列数值，列名为 `x` 与 `y`。其中 x 的范围为 $[-10, 10]$，y 的范围约为 $[-17.8564, 34.4055]$。模型以第一列为输入，第二列为连续目标，不将表头当作样本。

实验采用课程提供的本地数据文件。文件的 SHA256 摘要随运行结果保存，用于复现时核对输入数据的一致性。

3.2 白葡萄酒质量数据集

多元线性回归、学习率分析、岭回归及多项式回归均使用 `winequality-white.csv`。文件包含 4898 条记录，每条记录有 11 个理化特征，最后一列 `quality` 为质量评分。第一行是表头，字段之间使用分号分隔，读取时必须明确指定 `sep=';'`。

11 个输入字段依次为 fixed acidity、volatile acidity、citric acid、residual sugar、chlorides、free sulfur dioxide、total sulfur dioxide、density、pH、sulphates 和 alcohol。描述性统计见表2。不同特征的量纲差异明显，例如总二氧化硫的数值量级与密度、氯化物不同，因此直接在原始尺度上使用统一学习率会影响优化条件。

表 2: 白葡萄酒数据数值范围与描述性统计

字段	均值	样本标准差	最小值	最大值
fixed acidity	6.8548	0.8439	3.8000	14.2000
volatile acidity	0.2782	0.1008	0.0800	1.1000
citric acid	0.3342	0.1210	0.0000	1.6600
residual sugar	6.3914	5.0721	0.6000	65.8000
chlorides	0.0458	0.0218	0.0090	0.3460
free sulfur dioxide	35.3081	17.0071	2.0000	289.0000
total sulfur dioxide	138.3607	42.4981	9.0000	440.0000
density	0.9940	0.0030	0.9871	1.0390
pH	3.1883	0.1510	2.7200	3.8200
sulphates	0.4898	0.1141	0.2200	1.0800
alcohol	10.5143	1.2306	8.0000	14.2000
quality	5.8779	0.8856	3.0000	9.0000

质量评分虽然是整数，本实验遵循回归任务设置，将其视为连续响应变量，使用实数预测值计算 MSE，不将预测四舍五入为分类标签。评分 3、4、5、6、7、8、9 的样本数量分别为 20、163、1457、2198、880、175、5，主要集中在 5 和 6。整体均方误差不能单独说明极少数评分样本上的效果。

3.3 数据预处理与重复样本检查

多元线性回归、岭回归和多项式回归均采用同一白葡萄酒数据集，以保持模型之间的可比性。一维可视化采用该数据集中的 alcohol 特征，其数据划分与多变量实验一致。

数值检查确认白葡萄酒文件没有缺失值，输入和目标均为有限数。文件有 937 条重复记录，这里的 937 是按整行判断重复后，除首次出现记录之外的重复行数，不是重复组数。按照题目要求进行按行随机划分后，有 286 条测试记录与训练集中某条记录完全相同。

训练与测试**索引**没有交集，但这不意味着两者**内容**没有重复。保留重复行符合本次按行划分的协议，却会限制评估的独立性。因此，本报告的测试误差描述当前随机行划分下的表现，不将其解释为对完全独立生产批次的预测能力。若要评估更严格的泛化性能，可以另行按相同记录分组划分，或根据样本来源分批评估；这属于后续实验，不与本次规定划分的结果混报。

3.4 实验环境与程序组织

实验程序使用 Python，主要依赖 NumPy、pandas 和 Matplotlib。NumPy 用于矩阵运算与线性方程求解，pandas 用于数据读取与结果保存，Matplotlib 用于绘制拟合曲线和误差图。依赖包及最低版本列于 `requirements.txt`，运行方法见附录 A。

表 3: 程序文件与职责

文件	职责
`regression_core.py`	正规方程、BGD、岭回归、多项式特征与预测。
`run_all.py`	数据读取、划分、全部任务的训练、指标保存与作图。
`verify_results.py`	独立数值核验、索引检查与重复记录统计。
代码模版目录下的`task*.py`	五个课程模板入口，调用同一份已完成的核心实现。
`report/analyze_results.py`	使用已有测试预测，补充误差分布与极端误差诊断。
`outputs/`	指标、参数、逐轮损失、测试预测、图像及环境记录。

核心求解函数与实验入口分别组织，各组参数对照共享数据处理及目标函数实现。梯度更新采用批量梯度下降，每轮使用完整训练集。

3.5 训练验证与测试划分

外层划分使用 `np.random.RandomState(42)` 随机打乱行索引，前 $\lfloor 0.2n \rfloor$ 行作为测试集，其余作为训练集。数据没有按原始文件顺序直接截取，也没有对目标评分做分层划分。

表 4: 样本划分数量

数据	总样本	外层训练	外层测试
一元回归	120	96	24
白葡萄酒	4898	3919	979

葡萄酒样本量不能被 5 整除，因此向下取整后得到 3919 与 979，比例与 4:1 略有取整差异。岭回归和多项式模型需要比较候选参数，在 3919 条外层训练数据内再次用种子 43 划出 783 条验证样本，其余 3136 条用于内部拟合。内部验证确定候选参数后，再使用完整 3919 条训练数据重新训练，最后计算 979 条测试样本的误差。

评价协议的关键点。表中的验证误差来自内部 3136 条训练数据拟合出的模型；外层训练误差和测试误差来自 3919 条数据重训后的模型。因此，三列误差并不对应完全相同的训练样本数。验证数据在重训时可以并回训练集，测试数据始终不参与参数估计。

3.6 标准化与误差指标

对于第 j 个特征，仅在当前拟合训练集上计算

$$\mu_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}, \qquad \sigma_j = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_{ij}-\mu_j)^2}, \qquad z_{ij} = \frac{x_{ij}-\mu_j}{\sigma_j}.$$

验证与测试特征使用同一组 μ_j, σ_j。若某个特征的标准差接近零，实现将其尺度置为 1，以避免除零。截距列保持为 1，不参与标准化。描述性统计表中的样本标准差由 pandas 计算，分母为 $n-1$；模型标准化采用 NumPy 默认总体标准差，分母为 n，二者用途不同。

统一评价指标为

$$\mathrm{MSE}(y,\hat{y}) = \frac{1}{m}\sum_{i=1}^{m}(y_i-\hat{y}_i)^2.$$

均方误差会对少量大残差赋予较大权重。为解释多项式模型的异常结果，报告额外给出 MAE、绝对误差分位数和最差样本的误差占比，但主实验仍以题目要求的 MSE 为准，不在看到测试结果后更换评价准则。

4 基础实验：线性回归的参数估计

4.1 任务 1：一元线性回归与最小二乘法

4.1.1 模型设定

一元回归通过最小二乘估计确定输入与响应之间的线性关系，并利用训练与测试误差评价拟合效果。另构造 5 个输入点考察区间内预测与外推结果。设输入为 x_i、目标为 y_i，模型为

$$\hat{y}_i = wx_i + b.$$

将截距并入参数向量后，令

$$A=\begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix}, \quad \theta=\begin{bmatrix} w \\ b \end{bmatrix}, \quad \hat{\boldsymbol{y}}=A\theta.$$

这种写法使一元与多元线性回归可以共享同一个求解过程；在葡萄酒任务中，只需将前面的输入列扩展为 11 列。

4.1.2 正规方程推导

最小二乘目标是使残差平方和最小：

$$L(\theta)=\|A\theta-\boldsymbol{y}\|_2^2=\theta^TA^TA\theta-2\theta^TA^T\boldsymbol{y}+\boldsymbol{y}^T\boldsymbol{y}.$$

对 θ 求导并令梯度为零：

$$\nabla L=2A^TA\theta-2A^T\boldsymbol{y}=0 \quad \Longrightarrow \quad A^TA\theta=A^T\boldsymbol{y}.$$

当 A^TA 可逆时，得到题目中的正规方程解

$$\boxed{\theta=(A^TA)^{-1}A^T\boldsymbol{y}.}$$

是否在目标前除以样本数，并不改变最小二乘最优参数，因为只是将整个目标乘以一个正常数；但在后面的梯度下降中，目标缩放会改变同一学习率下的更新幅度。

4.1.3 实现步骤与稳定性处理

实现过程为：读取两列数据；按固定种子划分训练测试集；构造训练设计矩阵；计算 A^TA 与 A^Ty；求出参数后在训练及测试上分别预测。为避免显式逆矩阵带来的额外误差，程序优先用 `np.linalg.solve` 直接求解正规方程组。

Listing 1: 正规方程与病态矩阵回退

```python
def normal_fit(A, y):
    gram = A.T @ A
    if np.linalg.cond(gram) < 1e12:
        return np.linalg.solve(gram, A.T @ y)
    return np.linalg.pinv(A, rcond=1e-10) @ y
```

这里的伪逆回退用于设计矩阵秩不足或数值病态的情况；它仍然求解最小二乘问题，而不是改变成另一个预测目标。本次一元任务使用条件良好的两列矩阵，正常执行正规方程求解。

4.1.4 训练误差测试误差与五点预测

表 5: 正规方程训练与测试结果

训练样本	测试样本	w	b	训练 MSE	测试 MSE
96	24	2.520868	6.719009	3.375624	3.454386

实际回归方程为

$$\boxed{\hat{y} = 2.5208678471x + 6.7190094621.}$$

训练 MSE 为 3.375624，测试 MSE 为 3.454386，两者接近。由于测试集只有 24 条记录，该差异只能作为当前划分下的观察，不能据此断言模型已覆盖所有可能的数据分布。

表 6: 五个自行构造样本的预测结果

x	预测值 $\hat{y}$	说明
-12.0	-23.531405	区间外推
-3.0	-0.843594	区间内预测
0.0	6.719009	区间内预测
4.5	18.062915	区间内预测
11.0	34.448556	区间外推

5 个新点取 $-12, -3, 0, 4.5, 11$。其中 0 的预测值直接对应截距，有助于检查参数顺序是否写反；-3 和 4.5 位于样本输入区间内；-12 和 11 超出原始 $[-10, 10]$ 范围，用来展示外推。新点没有真实标签，因此这里只能报告预测值，不能计算它们的测试误差。表中的训练与测试 MSE 来自已有数据的固定划分，与这 5 个构造点不是同一回事。

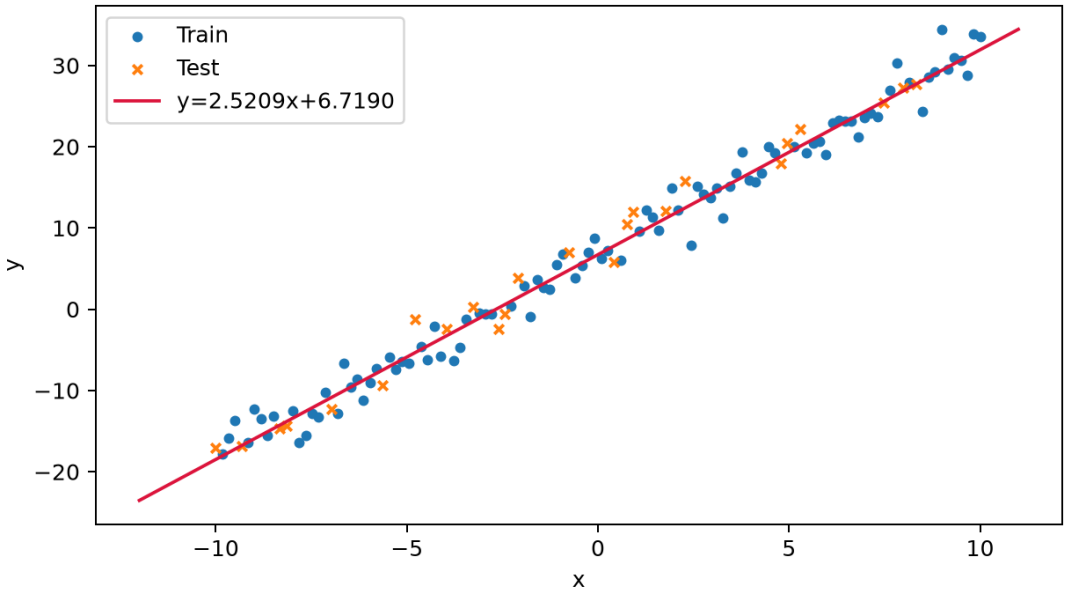


图 1: 一元回归训练与测试散点及最小二乘拟合直线

图1中，训练点和测试点分别用不同标记表示，回归直线只由训练数据估计。散点大致沿直线分布，残差并不为零，说明最小二乘找到的是整体平方误差最小的折中直线，而不是让每个训练点都落在线上。

4.1.5 思考题：正规方程求解的核心步骤

正规方程的核心是求解 $A^TA\theta = A^Ty$，即由设计矩阵构造系数矩阵后，求出对应线性方程组的参数解。公式中写成 $(A^TA)^{-1}A^Ty$，其关键前提是 A^TA 可逆；实际程序用线性方程求解器完成这一步，避免显式计算逆矩阵。

4.1.6 思考题：正规方程在什么情况下会失败

以下情况可能导致求解失败或数值不稳定：

1. **列向量不独立**。例如两个特征完全相同，或已经有常数列又追加截距，导致 A^TA 奇异。
2. **独立样本不足**。当参数数量超过可提供独立约束的样本数量时，最小二乘解通常不唯一。
3. **近似共线或尺度悬殊**。即使矩阵形式上可逆，也可能因条件数很大而使浮点误差被放大。

对于满列秩矩阵，在 2 范数下 $\kappa(A^TA) = \kappa(A)^2$，形成正规方程会进一步恶化条件数。实际处理可以是移除重复特征、标准化、使用 QR/SVD 最小二乘，或者添加岭惩罚。单纯调用求逆函数并不能解决病态问题。

4.2 任务 2：多元线性回归与批量梯度下降

4.2.1 数据读取与预处理步骤

多元线性回归实验以白葡萄酒的 11 个特征预测 quality。实现先读取分号分隔的文件，明确选择前 11 列为 X，最后一列为 y，然后按 4:1 随机划分。划分完成后才计算标准化统计量，避免从测试集获取分布信息。

Listing 2: 数据读取及仅基于训练集的标准化

```
df = pd.read_csv(csv_path, sep=';')
X = df.iloc[:, :-1].to_numpy(float)
y = df.iloc[:, -1].to_numpy(float)
idx = np.random.RandomState(42).permutation(len(X))
k = int(0.2 * len(X))
test_idx, train_idx = idx[:k], idx[k:]
mean = X[train_idx].mean(axis=0)
std = X[train_idx].std(axis=0)
std = np.where(std < 1e-12, 1.0, std)
Z_train = (X[train_idx] - mean) / std
Z_test = (X[test_idx] - mean) / std
```

标准化使不同量纲的特征具有可比尺度，也改善梯度下降的步长选择条件，但不能消除所有相关性。例如密度、残糖、酒精含量等特征仍可能存在线性相关结构，因此优化仍有不同曲率方向。

4.2.2 MSE 目标梯度推导与更新公式

将标准化后的矩阵追加常数列得到 $A = [Z, \mathbf{1}]$，参数包含 11 个权重和 1 个截距。目标函数与梯度为

$$J(\theta) = \frac{1}{n}\|A\theta - y\|_2^2, \qquad \nabla J(\theta) = \frac{2}{n}A^T(A\theta - y).$$

每轮更新

$$\boxed{\theta^{(t+1)} = \theta^{(t)} - \alpha\frac{2}{n}A^T(A\theta^{(t)} - y).}$$

本实验选择 BGD，每轮梯度使用全部 3919 个训练样本。它与一次只用单个样本的 SGD、一次使用部分样本的 mini-batch GD 不同。BGD 在固定初始参数和训练数据时没有额外抽样噪声，便于比较学习率的影响。

4.2.3 核心实现与逐轮记录

Listing 3: 批量梯度下降的核心训练循环

```
theta = np.zeros(A.shape[1])
history = []
for epoch in range(3000):
    residual = A @ theta - y_train
    gradient = (2.0 / len(A)) * (A.T @ residual)
    theta -= 0.05 * gradient
    loss = np.mean((A @ theta - y_train) ** 2)
    history.append(float(loss))
```

实际通用函数允许传入学习率和轮数，并在损失非有限或超过 10^{20} 时终止，保留异常记录供学习率实验分析。训练历史记录的是**更新后**的 MSE，第一项对应第一次参数更新，而不是全零初始化时的损失。初始截距为 0，而目标均值约为 5.87，所以训练初期损失较大，截距快速接近目标均值后误差明显下降。

学习率固定为 0.05，训练 3000 轮；全部历史保存于 `task2_history.csv`。训练过程中不使用测试误差作为提前停止条件，本次也未对学习率 0.05 进行针对测试集的选择。

4.2.4 收敛曲线与最终结果

表 7: BGD 与同一划分上的闭式解对照

求解方法	训练 MSE	测试 MSE
BGD，$\alpha = 0.05$，3000 轮	0.5627079481	0.5695005217
普通最小二乘闭式解	0.5627079415	0.5694884856

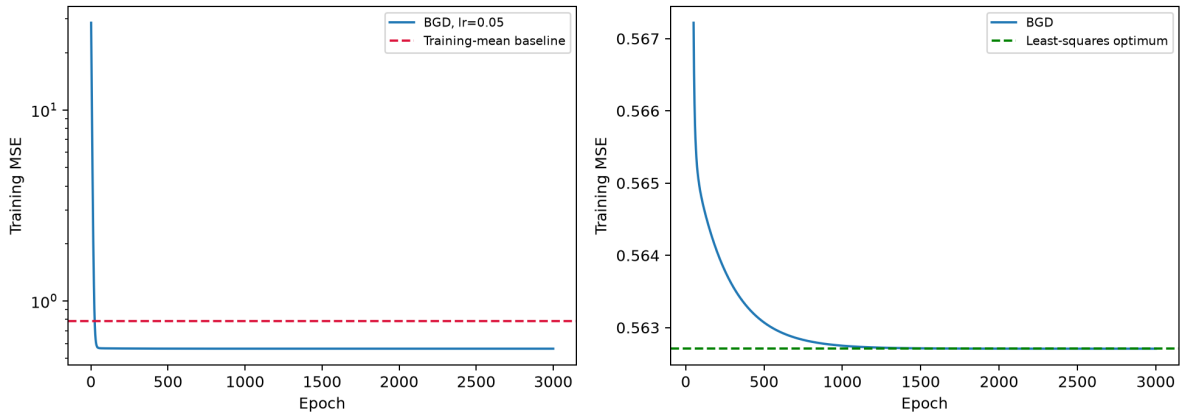


图 2: BGD 训练过程及后期收敛局部图，虚线分别为均值预测基线与最小二乘最优值

训练损失与闭式解相差约 6.64×10^{-9}，参数向量的欧氏距离约为 0.000552。损失差很小而参数仍有细微差异，是因为低曲率方向上的参数变化对目标影响较弱。对当前训练问题而言，3000 轮已经使 BGD 非常接近最小二乘解，进一步增加轮数不会保证测试误差持续下降。

图2左侧采用对数纵轴展示全过程，右侧使用线性纵轴放大第 50 轮之后的变化。后期训练误差

仍向闭式最优值下降，表明视觉上接近水平的曲线仍可能包含可降低的优化误差。不同轮次的数值见表8。

表 8: BGD 训练损失及距最小二乘最优值的差距

轮数	训练 MSE	$J_t - J_*$
1	28.650963	2.809e+01
10	4.795592	4.233e+00
20	1.088857	5.261e-01
30	0.632982	7.027e-02
40	0.575269	1.256e-02
50	0.567219	4.511e-03
100	0.564804	2.096e-03
300	0.563575	8.671e-04
1000	0.562749	4.090e-05
3000	0.562708	6.638e-09

第 300 轮距最优训练损失的差为 8.6714×10^{-4}，第 3000 轮缩小至 6.6379×10^{-9}。这部分差距由有限次迭代造成，属于优化误差。最优训练损失本身则同时受模型设定、数据噪声与样本实现的影响，二者应分别讨论。

4.2.5 均值基线与决定系数

以训练目标均值 $\bar{y}_{\mathrm{tr}}$ 作为常数预测，训练 MSE 为 0.786217，测试 MSE 为 0.776317。该基线不使用任何测试标签估计预测参数，可用于衡量引入理化特征后的误差改进。

测试集的标准决定系数定义为

$$R^2_{\mathrm{te}} = 1 - \frac{\sum_{i \in \mathrm{te}} (y_i - \hat{y}_i)^2}{\sum_{i \in \mathrm{te}} (y_i - \bar{y}_{\mathrm{te}})^2}.$$

分母使用测试集自身的目标均值，仅作为评价统计量，不参与模型训练。若将分母改为训练均值基线的测试 SSE，得到的是相对于该常数预测的误差改善率，两者数值接近但定义不同。

表 9: 迭代预算与测试性能的补充比较

模型	训练 MSE	测试 MSE	测试 RMSE	测试 R^2
BGD 300	0.563575	0.574417	0.757903	0.259060
BGD 3000	0.562708	0.569501	0.754653	0.265402
Closed form	0.562708	0.569488	0.754645	0.265418

3000 轮 BGD 的测试 RMSE 为 0.754653，标准 R^2 为 0.265402；相对于训练均值预测的测试误差改善率为 0.266407。上述结果描述当前线性模型在本次划分下的解释能力，不能据此推断数据可达到的预测精度上限。

4.2.6 参数解释与原始量纲还原

表 10: 标准化坐标下的线性模型与岭回归参数

特征	BGD 权重	岭回归权重 $\lambda = 1$
fixed acidity	0.038735	0.038046
volatile acidity	-0.194572	-0.194570
citric acid	-0.007281	-0.007292
residual sugar	0.365826	0.363764
chlorides	-0.000585	-0.000746
free sulfur dioxide	0.085272	0.085378
total sulfur dioxide	-0.010100	-0.010251
density	-0.375158	-0.372207
pH	0.090386	0.089819
sulphates	0.073637	0.073459
alcohol	0.281169	0.282333
intercept	5.871396	5.871396

参数表中的权重对应标准化特征 z_j。例如某权重为正，表示**在其余特征固定的线性模型内**，该标准化特征增大时预测值增大。这不是单独按该特征排序得到的边际规律，更不是因果关系。原始单位下的参数满足

$$\tilde{w}_j = \frac{w_j}{\sigma_j}, \qquad \tilde{b} = b - \sum_j \frac{w_j \mu_j}{\sigma_j}.$$

因此密度的原始单位权重数值较大，并不直接说明其重要性一定最高；其取值尺度本身很小。原始单位系数已经保存于 `task2_weights.csv`，可以用两种坐标下的参数对同一样本预测并核对一致性。

4.2.7 解析解与迭代解的比较

正规方程构造 $A^T A$ 的主要代价约为 $O(np^2)$，求解约为 $O(p^3)$，适合当前这种特征数较小的线性问题。BGD 单轮约为 $O(np)$，需执行多轮并设置步长，但可以避免直接构造大规模特征协方差矩阵，并容易扩展为小批量训练。

线性回归的闭式解作为迭代求解的数值基准，用于核对梯度、截距处理与目标函数定义。两种方法的比较采用相同数据划分与标准化，使差异主要反映优化误差。

5 中级实验：学习率与收敛性分析

5.1 对照实验设计

学习率实验在多元线性回归实验的相同数据与 BGD 实现上比较学习率。候选为

$$\alpha \in \{0.001, 0.01, 0.05, 0.1, 0.3, 1.0\}.$$

每组使用相同的 3919 条训练样本、979 条测试样本、训练集标准化统计量、全零参数和 3000 轮预算。这样不同曲线之间主要变化因素是学习率，避免将不同随机划分造成的差异误认为学习率效果。

仅比较最终 3000 轮的误差，可能掩盖收敛速度差异。因此额外定义“达到阈值轮数”：设闭式解训练损失为 J_*，记录首次满足

$$J(\theta^{(t)}) \le J_* + 10^{-4}$$

的轮数。这个阈值来自训练目标，不依赖测试误差。未达到阈值并不一定表示算法理论上不收敛，只表示在本次固定预算内尚未达到指定精度。

5.2 学习率曲线与数值结果

表 11: 不同学习率的收敛速度与最终误差

学习率	训练 MSE	测试 MSE	达到阈值轮数	状态
0.001	0.565884	0.578376	未达到	稳定
0.010	0.562943	0.571908	未达到	稳定
0.050	0.562708	0.569501	796	稳定
0.100	0.562708	0.569489	398	稳定
0.300	0.562708	0.569488	132	稳定
1.000	发散	–	未达到	发散

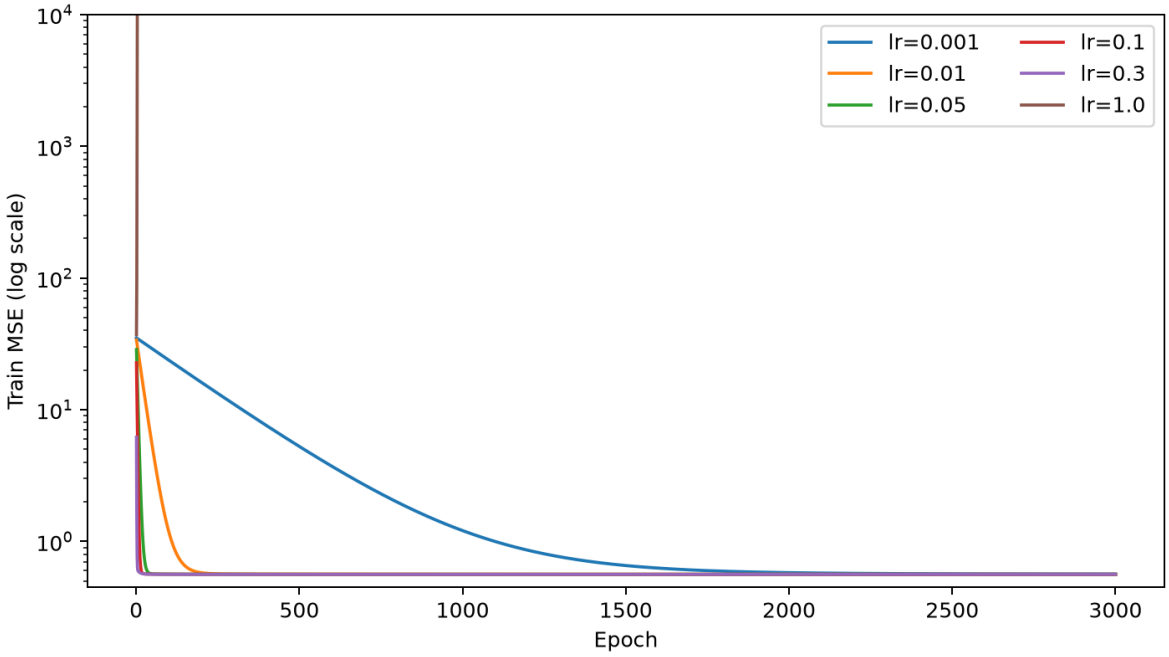


图 3: 相同划分与初始化下不同学习率的训练 MSE 曲线

$\alpha = 0.001$ 更新幅度小，3000 轮后训练 MSE 为 0.565884，尚未进入与最优值相差 10^{-4} 的范围。$\alpha = 0.01$ 已较接近最优，但仍未达到这一阈值。$\alpha = 0.05$、0.1、0.3 分别在 796、398、132 轮首次达到阈值，其中 0.3 在本次候选中最快。

$\alpha = 1.0$ 的损失在第 15 轮超过 10^{20}，实际记录为 8.0874×10^{20}，于是终止该组训练并将状态标为发散。为了使其他曲线可读，图中纵轴上限限制为 10^4，超过范围的发散部分不显示；原始损失仍保存在 `task3_histories.csv`，发散前的迭代记录均予以保留。

5.3 学习率收敛条件的理论分析

对于二次目标，Hessian 为

$$H = \nabla^2 J = \frac{2}{n} A^T A.$$

在 Hessian 的某个特征方向上，误差更新等价于乘以 $1 - \alpha\lambda_i(H)$。要使所有非零曲率方向的误差缩小，需要

$$|1 - \alpha\lambda_i(H)| < 1, \quad \Longrightarrow \quad 0 < \alpha < \frac{2}{\lambda_{\max}(H)}.$$

本次训练矩阵对应上界约为 0.310016。0.3 位于稳定区间内，而 1.0 明显超过上界。因此观察到的稳定和发散，与二次目标的曲率分析一致。

进一步计算得 $L = \lambda_{\max}(H) = 6.451283$、$\mu = \lambda_{\min}(H) = 0.043583$，谱条件数为 $L/\mu = 148.024067$。对于该正定二次目标，固定步长在所有特征方向上的最坏情况收缩因子为 $\max_i |1 - \alpha\lambda_i(H)|$，其极小极大解为

$$\alpha_{\text{mm}} = \frac{2}{L + \mu} = 0.307936.$$

该值与候选步长 0.3 相近，但这一结论针对最坏方向的渐近收缩率；特定初始参数达到某个有限损失阈值的轮数，还取决于初始误差在各特征方向上的分量。

5.4 分析与解释：学习率过小对收敛的影响

学习率过小时，每次沿目标下降方向移动得太短，计算预算主要消耗在重复的小步更新上。本实验中，0.001 对应的训练 MSE 在 3000 轮后仍为 0.565884，0.01 也未达到距最优损失不超过 10^{-4} 的阈值。它们在当前理论稳定区间内，因此属于固定迭代预算下收敛缓慢，不能据此判为发散。

5.5 分析与解释：学习率过大对收敛的影响

学习率过大时，参数可能越过最优点，在大曲率方向上来回振荡并逐渐放大，最终导致损失爆炸。本实验中，1.0 超过稳定上界 0.310016，第 15 轮损失即超过 10^{20}，与理论分析一致。标准化有助于改善条件，但不能保证任意较大步长均可稳定收敛。

5.6 分析与解释：最佳学习率及其适用范围

若按**达到既定训练损失阈值的速度**评价，本次候选中 0.3 最好。它 3000 轮后的误差与 0.1 几乎一致，不能将末位浮点差异视为统计上显著的预测性能提升。0.05 作为多元线性回归实验的主设置也能稳定逼近最优值，只是达到相同阈值需要更多轮数。

学习率 0.3 接近 0.310016 的稳定上界，其有效性依赖于当前数据矩阵及目标函数的尺度。特征变换、目标缩放或多项式阶数发生变化时，需要重新考察 Hessian 及稳定步长范围。本实验依据训练目标评价收敛速度，测试误差仅用于最终性能比较。

6 高级实验：岭回归与正则化分析

6.1 目标函数与参数估计

普通最小二乘只要求训练残差小，当特征相关或参数较多时，可能出现幅值较大且不稳定的系数。岭回归在误差项之外加入权重的平方惩罚：

$$L_\lambda(w,b)=\sum_{i=1}^{n}(z_i^Tw+b-y_i)^2+\lambda\|w\|_2^2,\qquad \lambda\geq 0.$$

本实验**不惩罚截距**。截距反映目标整体水平，若直接惩罚截距，会使预测均值额外向零收缩；这与约束特征权重的目的不同。设 $A=[Z,\mathbf{1}]$，$D=\mathrm{diag}(1,\ldots,1,0)$，则

$$\nabla L_\lambda=2A^T(A\theta-y)+2\lambda D\theta=0,$$

得到

$$\boxed{(A^TA+\lambda D)\theta=A^Ty.}$$

这里的惩罚相对于 **SSE** 定义。如果改成 $\mathrm{MSE}+\lambda'\|w\|^2$，与本实验等价时应有 $\lambda'=\lambda/n$。因此不同实现中的同名 λ 不能在未核对目标缩放时直接比较大小。

6.2 闭式解实现与主实验设置

Listing 4: 不惩罚截距的岭回归闭式解

```python
def ridge_fit(A, y, lam=1.0):
    penalty = np.eye(A.shape[1])
    penalty[-1, -1] = 0.0
    return np.linalg.solve(
        A.T @ A + lam * penalty,
        A.T @ y
    )
```

实际函数还检查 λ 非负，并对 $\lambda=0$ 调用普通最小二乘求解。本次主实验固定 $\lambda=1$，使用与多元线性回归实验相同的外层训练测试划分和标准化，得到训练 MSE 为 0.562708，测试 MSE 为 0.569571，标准化权重的 L_2 范数为 0.640930。

与普通最小二乘的权重范数 0.643762 相比，$\lambda=1$ 的收缩幅度较小；这与 SSE 目标下 A^TA 随训练样本数量累积的尺度有关。惩罚参数必须结合目标和样本量理解，其作用强度由惩罚项与数据拟合项的相对尺度决定。

6.3 选做实验：不同正则化参数对权重与测试误差的影响

正则化参数取值设为

$$\lambda\in\{0,0.01,0.1,1,10,100,1000,10000\}.$$

0 作为普通最小二乘基线，其余为正惩罚。内部训练集上拟合每个候选并计算验证 MSE；同时将候选在完整外层训练集上重新拟合，以统一展示外层训练与测试结果。

表 12: 正则化参数与误差和权重范数的关系

λ	训练 MSE	验证 MSE	测试 MSE	$\|w\|_2$
0	0.562708	0.576780	0.569488	0.643762
0.01	0.562708	0.576780	0.569489	0.643733
0.1	0.562708	0.576785	0.569497	0.643475
1	0.562708	0.576832	0.569571	0.640930
10	0.562746	0.577275	0.570248	0.618631
100	0.563926	0.579996	0.573563	0.524880
1000	0.578998	0.601436	0.582924	0.366444
10000	0.672148	0.709698	0.661905	0.128810

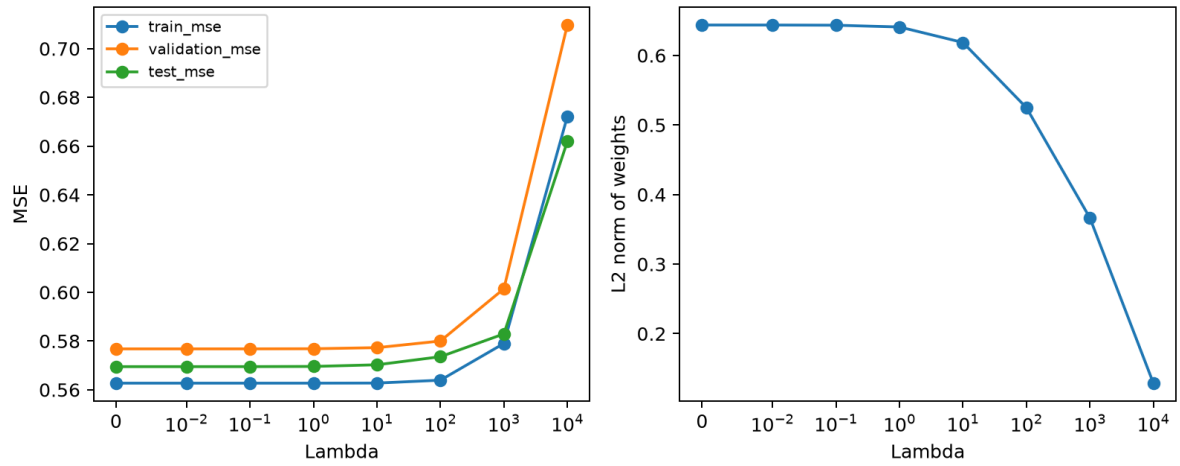


图 4: 不同正则化参数下的误差及标准化权重范数

6.3.1 分析与解释：权重大小随正则化参数的变化

由于候选含 0 且跨度较大，横轴采用可容纳 0 的对称对数尺度。图4右侧显示，权重范数随正则化增大而下降，从 0.643762 减小到 0.128810。这里比较的是整体范数，不要求每个单独权重都严格单调变化；特征相关时，不同系数之间可能重新分配。

6.3.2 分析与解释：测试误差变化及过强正则化的影响

本次验证误差最低的是 $\lambda = 0$，说明当前划分和原始 11 维线性模型下，没有观察到正则化参数取正值时带来的验证改进。如果只在正参数中比较，0.01 最接近普通最小二乘基线。主实验设置 $\lambda = 1$ 的目的在于实现并评估岭回归，不代表它通过验证集胜出。

当 λ 增至 10000 时，训练 MSE 上升到 0.672148、测试 MSE 上升到 0.661905，模型对输入变化的响应被压缩，表现为惩罚过强导致的欠拟合。岭回归可以通过引入偏差降低方差，但是否改善最终误差取决于数据、模型维度与参数；不能因为算法加入了正则化，就预设测试结果一定更好。

6.4 正则化与矩阵条件数

表 13: 正则化强度与正规方程矩阵的条件数

λ	$\kappa_2(A^TA+\lambda D)$	权重范数	测试 MSE
0	148.0241	0.643762	0.569488
1	146.3224	0.640930	0.569571
10	132.6128	0.618631	0.570248
100	68.7232	0.524880	0.573563
1000	12.5680	0.366444	0.582924
10000	5.7773	0.128810	0.661905
100000	28.7424	0.020726	0.752704

当 $\lambda = 1000$ 时，正规方程矩阵的条件数由 148.0241 降至 12.5680，说明惩罚项改善了求解条件。然而对应测试 MSE 为 0.582924，高于无正则的 0.569488；数值条件改善并不直接等价于泛化误差降低。

截距不受惩罚时，D 为半正定矩阵，但对 $n > 0$、$\lambda > 0$，矩阵 $A^TA + \lambda D$ 仍为正定。对任意非零向量 (u, c)，有

$$\begin{bmatrix} u \\ c \end{bmatrix}^T (A^TA + \lambda D) \begin{bmatrix} u \\ c \end{bmatrix} = \|Zu + c\mathbf{1}\|^2 + \lambda\|u\|^2 > 0.$$

若 $u \neq 0$，惩罚项为正；若 $u = 0$，则 $c \neq 0$ 且第一项为 $nc^2 > 0$。由于截距方向未同步正则化，条件数随 λ 增大不必始终下降，表中 $\lambda = 100000$ 时的回升即体现了这一点。

7 拓展实验：多项式回归与模型选择

7.1 多变量建模与单变量可视化

多项式回归采用白葡萄酒数据，对 11 个输入特征进行多项式展开，考察模型复杂度与泛化误差的关系。另以 alcohol 为单一输入建立对照模型，用于观察不同阶数下的拟合曲线。

两组实验的作用不同：11 维主实验回答多变量模型增加复杂度后效果如何；单特征实验回答同一个可视化自变量下曲线如何随阶数变化。11 维模型不存在一条能与所有 alcohol 散点一一对应的一维曲线，因而没有把固定其他特征的条件切片误称为整体拟合结果。

7.2 多项式特征与参数规模

对于两个输入，二阶展开包括

$$\phi_2(x_1, x_2) = (x_1, x_2, x_1^2, x_1x_2, x_2^2).$$

除了每个特征的幂次，还应包括交互项。一般情况下，p 个变量、总次数不超过 d 的非恒定单项式个数为

$$q_d = \binom{p+d}{d} - 1.$$

当 $p = 11$ 时，1、2、3、4 阶分别有 11、77、363、1364 个非恒定特征；追加截距后，参数总数分别为 12、78、364、1365。非恒定项数量与含截距的参数总数相差 1，比较不同实现时需要采用相同统计口径。

Listing 5: 多项式特征与交互项的生成

```
from itertools import combinations_with_replacement

powers = [c for d in range(1, degree + 1)
          for c in combinations_with_replacement(
              range(X.shape[1]), d)]
P = np.column_stack([
    np.prod(X[:, columns], axis=1)
    for columns in powers
])
```

使用可重复组合可以避免同时生成 x_1x_2 与 x_2x_1 这样的重复项。常数列单独追加，避免在多项式展开和设计矩阵构造时重复引入截距。

7.3 训练步骤标准化与 SVD 求解

每个阶数执行以下过程：

1. 在当前拟合训练集上计算原始 11 维特征的均值和标准差，得到标准化输入。
2. 展开所有总次数不超过指定阶数的单项式。
3. 在当前训练集上再次计算展开特征的均值和标准差，缩放各列后追加截距。
4. 使用 SVD 最小二乘求参数，保存两级标准化统计量。
5. 预测时依次应用相同的原始标准化、特征展开和展开后标准化，不在验证或测试集重新估计统计量。

高阶设计矩阵存在较大的条件数，直接形成 A^TA 会放大数值问题。因此主实验采用

Listing 6: 多项式模型的 SVD 最小二乘求解

```
theta, _, rank, singular = np.linalg.lstsq(
    A_train, y_train, rcond=1e-10
)
y_pred = A_test @ theta
```

多项式特征由程序生成，参数通过 NumPy 线性代数工具估计。1、2、4 阶重训矩阵的数值秩分别为 12、78、1365，均达到相应列数；条件数分别约为 12.17、222.29、1.6652×10^7。四阶矩阵在数值满秩的同时具有较高条件数，其解对输入扰动的敏感性仍需结合样本外误差考察。

7.4 不同阶数的训练验证与测试结果

表 14: 11 维多项式回归结果

阶数	非恒定项	参数总数	训练 MSE	验证 MSE	测试 MSE
1	11	12	0.562708	0.576780	0.569488
2	77	78	0.492450	0.522458	0.619978
3	363	364	0.410782	0.615921	1.837658
4	1364	1365	0.237318	10.464700	421.428415

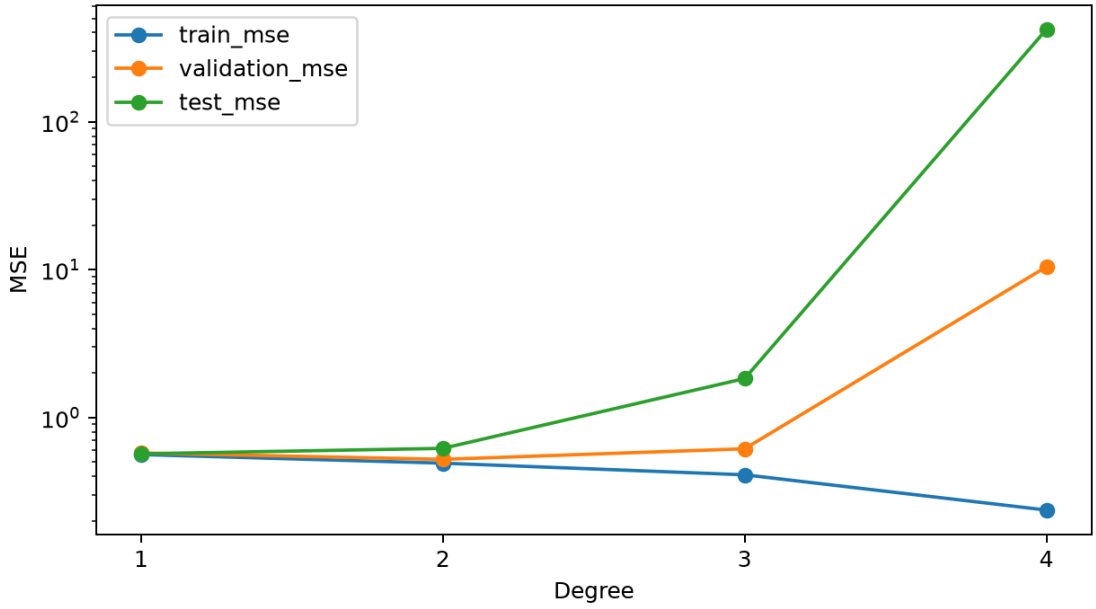


图 5: 11 维多项式模型复杂度与训练验证测试误差

从训练误差看，阶数从 1 增至 2 和 4 时，MSE 分别由 0.562708 降至 0.492450 和 0.237318，说明增加特征提高了训练集拟合能力。但验证误差只在二阶下降，四阶上升到 10.464700，测试误差更达到 421.428415。四阶模型的训练与样本外误差出现巨大差距，表明高阶模型存在显著过拟合。

补充三阶实验后，训练 MSE 进一步降至 0.410782，验证 MSE 为 0.615921，测试 MSE 为 1.837658。误差在三阶已经明显恶化，四阶失稳并非仅由阶数 1、2、4 之间缺少中间观察点造成。加入三阶候选后，内部验证仍选择二阶模型。

二阶验证 MSE 为 0.522458，低于一阶的 0.576780，按事先规定的验证准则选择二阶。用完整训练集重训后，二阶测试 MSE 为 0.619978，却高于一阶的 0.569488。这个结果需要如实保留：单次验证划分存在波动，验证最优不保证在独立测试样本上仍然最优。若在看到测试结果后宣布改选一阶，再将同一个测试误差当作无偏的最终性能，会引入测试集选择偏差。

7.5 单特征散点与 1 阶 2 阶 4 阶拟合曲线

为得到可直接解释的平面图，使用 alcohol 预测 quality，保留同一组外层训练测试索引。每个阶数只使用 alcohol 的 1 至 d 次幂，不使用其他 10 个输入。标准化仍仅来自训练集，曲线横轴还原为原始酒精含量，图中散点为训练样本。

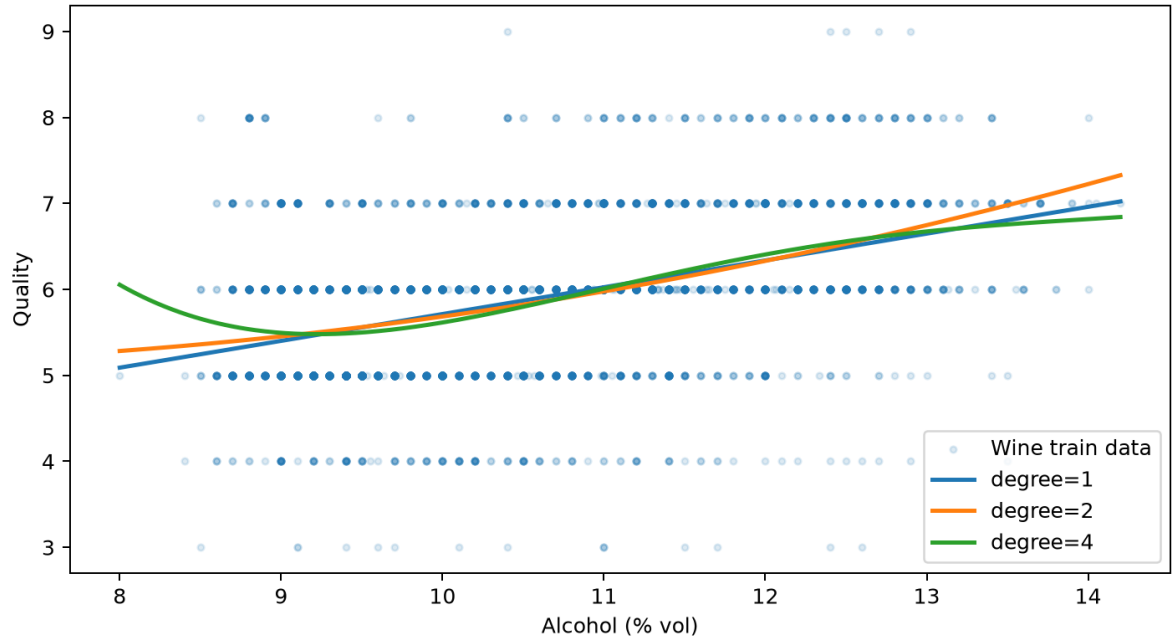


图 6: 白葡萄酒 alcohol 单特征的散点与不同阶数拟合曲线

表 15: alcohol 单特征多项式回归结果

阶数	训练 MSE	测试 MSE
1	0.639724	0.618296
2	0.637425	0.616539
4	0.632365	0.615325

在该单特征实验中，四阶测试 MSE 为 0.615325，略低于二阶的 0.616539 和一阶的 0.618296，没有出现 11 维四阶模型的误差爆炸。两者并不矛盾：单特征四阶只有 4 个非恒定特征，而 11 维四阶有 1364 个；参数规模、交互关系与数值条件不同。

图6还显示，相同酒精含量下有多个不同质量评分，单个变量不能完整解释目标。四阶曲线在输入左端有弯曲，不能仅凭这一形状就断言过拟合，应结合测试误差与其他诊断；当前单次划分上的小幅改善也不足以证明四阶在所有新数据上都更好。

7.6 多变量模型的条件切片

为直接观察 11 维模型沿 alcohol 方向的预测形状，将其余 10 个原始特征固定为外层训练均值，仅改变 alcohol。在此设定下，曲线由前述多变量模型计算；散点仍为训练观测在 alcohol 轴上的投影，因其其他特征并未固定，不能把散点与曲线的垂直距离解释为原模型残差。

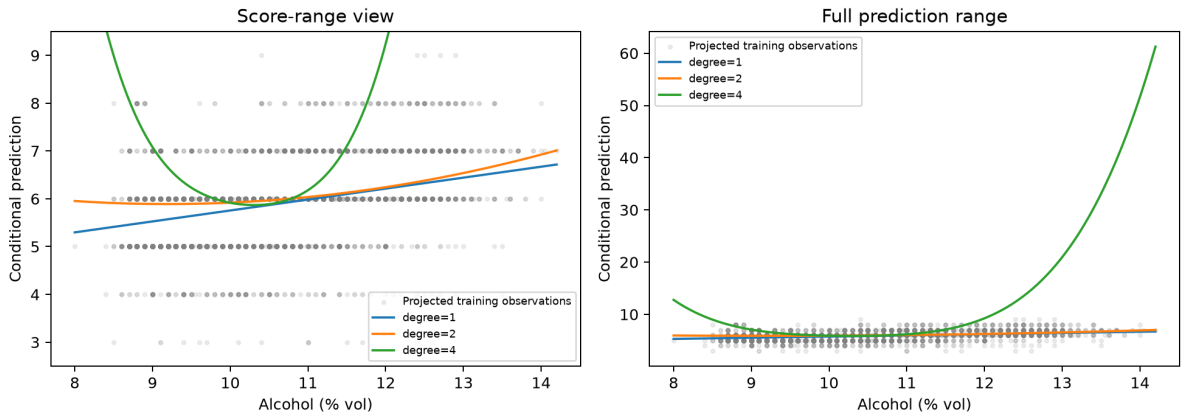


图 7: 11 维模型在其他特征固定为训练均值时的条件切片，左图显示评分区间，右图显示完整预测范围

四阶条件切片的最大预测值为 61.264847，远超观测质量评分范围 3 至 9。均值组合可能偏离真实样本的联合分布，因此该切片用于诊断模型对特定方向的响应，不作为独立测试误差估计。它与单变量拟合曲线的区别在于：前者保留多变量模型及其交互项，后者重新拟合只含 alcohol 的模型。

7.7 分析与解释：哪个阶数的拟合效果最好

对于 11 维多项式主实验，若以训练 MSE 衡量拟合程度，四阶最低，为 0.237318；若按预先设定的验证集选择模型，二阶最好，验证 MSE 为 0.522458。因此本实验的模型选择结果为二阶。独立测试集上的实际排序则是一阶最好，其 MSE 为 0.569488，低于二阶的 0.619978。验证与测试排序存在差异，应分别报告，不能把训练拟合最好等同于泛化最好。

对于 alcohol 单特征曲线实验，四阶测试 MSE 为 0.615325，在所比较的 1、2、4 阶中最低，但与二阶和一阶的差距较小。该结论仅适用于单特征模型及当前数据划分，不应直接替代 11 维主实验的模型选择结果。

7.8 高阶模型误差尾部的进一步诊断

只报告四阶测试 MSE 为 421.428415，难以判断是大多数样本都很差，还是少数预测异常主导了误差。为此，对已保存的 979 条测试预测计算绝对误差分布，不重新训练模型、不改变选参结果。

表 16: 不同阶数模型的测试绝对误差与尾部集中度

阶数	MAE	绝对误差中位数	95% 分位数	最大绝对误差	最差 10 点 SSE 占比
1	0.5865	0.4924	1.5091	4.2133	13.35%
2	0.5674	0.4659	1.3737	10.8638	28.63%
4	1.6790	0.5103	2.7791	606.3831	99.70%

四阶绝对误差中位数约 0.5103，而最大绝对误差达到 606.3831。最差 10 条记录约占测试样本的 1.02%，却贡献了 99.70% 的四阶测试 SSE。因此，四阶 MSE 爆炸主要由极少数极端残差驱动，但其 95% 绝对误差分位数也升高到 2.7791，不能据中位数尚可就认为该模型可靠。

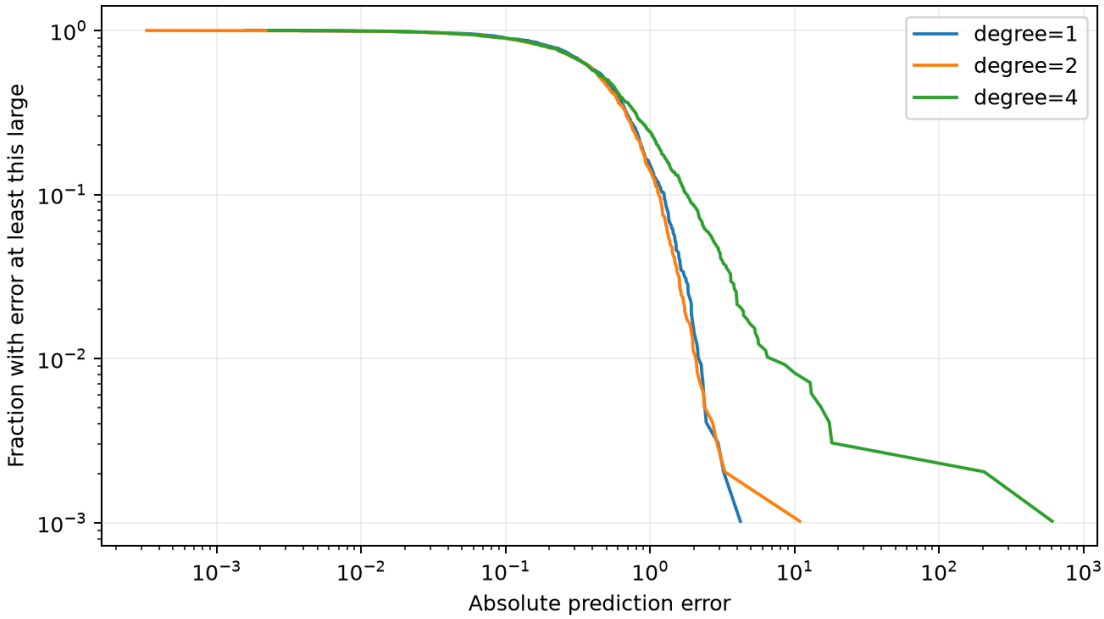


图 8: 不同阶数模型的测试绝对误差尾部分布，双轴为对数刻度

图8的纵轴表示绝对误差至少达到横轴给定值的样本比例。四阶曲线延伸到远大于其他模型的区域，反映其长尾风险。该图只使用已有测试集做事后诊断，没有将异常点移除后重算主实验，也没有据此改变验证集选出的阶数。

表 17: 四阶模型误差最大的五条测试记录

原文件零基行号	真实质量	四阶预测值	占测试 SSE
1526	6	-600.3831	89.12%
4745	3	-202.4703	10.23%
1417	3	-15.1069	0.08%
1551	6	23.3925	0.07%
1024	6	21.1367	0.06%

原文件零基行号 1526 的记录，真实质量为 6，四阶预测约为 −600.3831，单条记录贡献了 89.12% 的测试 SSE；行号 4745 的记录贡献约 10.23%。表中行号不包含 CSV 表头，并从 0 开始计数。回归模型没有输出范围约束，高阶多项式也不会天然保证预测落在评分范围内。报告保留这些预测，不进行事后裁剪，确保各模型使用同一 MSE 评价规则。

二阶的 MAE 约 0.5674、绝对误差中位数约 0.4659，均低于一阶，但最大绝对误差约 10.8638，高于一阶的 4.2133。这解释了二阶在多数样本上可能更贴近目标，却因少数大残差得到更高 MSE 的现象。MSE 和 MAE 强调的误差结构不同，不能只挑选更有利的一个指标作结论。

7.9 分析与解释：阶数过高时的过拟合现象

一阶相对于二阶的训练与验证误差都较高，说明线性关系可能遗漏部分结构；但一阶在当前测试 MSE 上最好，所以不能仅据训练误差更大就将其判为不可用。四阶则同时具有较低训练误差、较高验证误差和极端测试残差，具有明确的高方差与不稳定预测表现。

后续可在训练集内部采用多折交叉验证选择阶数，并通过岭惩罚约束高阶系数。标准化与 SVD 主要改善数值条件，模型复杂度仍需通过参数约束和样本外评价控制。进一步改进应在独立评估数据上验证，以区分模型调整带来的收益与对当前测试样本的适应。

8 结果验证与综合讨论

8.1 独立求解路径的复核

为考察迭代预算与数值求解方式的影响，补充运行 300 轮 BGD，并使用仅在原始特征上标准化的多项式最小二乘路径进行复核。复核保持数据划分不变，用于区分迭代次数、特征列统计口径及数值实现对结果的影响。

一元回归参数与 NumPy 的多项式一次拟合结果一致；岭回归在相同惩罚参数下的误差与权重范数一致。多项式的独立路径使用一次原始特征标准化和 `rcond=None`，与本文两级标准化路径的四阶测试预测最大差约为 5.60×10^{-9}，测试 MSE 均为 421.428415，支持异常误差来自拟合模型本身，而非第二次标准化或求解截断造成的数值偏差。

300 轮 BGD 的训练与测试 MSE 分别为 0.563575 和 0.574417；3000 轮时分别为 0.562708 和 0.569501。在其他设置相同的情况下，增加迭代次数减小了有限次更新带来的优化误差。

8.2 算法实现的数值验证

`verify_results.py` 已实际运行并通过以下检查：

1. 将正常设计矩阵的正规方程解与 NumPy SVD 最小二乘解对照，参数在给定浮点容差内一致。
2. 人为构造重复特征列，核对伪逆回退后的预测与独立最小二乘预测一致，确认奇异情况不会直接崩溃。
3. 用中心有限差分计算 MSE 的数值梯度，与解析梯度 $2A^T(A\theta - y)/n$ 对照。
4. 对岭回归解检查一阶最优条件 $A^T(A\theta - y) + \lambda D\theta \approx 0$。
5. 将全部目标整体加 100，检查岭回归权重保持不变、截距增加 100，验证截距未被惩罚。
6. 对输入 $(2, 3)$ 检查二阶展开为 $(2, 3, 4, 6, 9)$，确认交互项和幂次顺序。
7. 核对一阶多项式预测与同数据上的普通最小二乘预测一致。
8. 检查训练与测试索引无交集、样本数守恒、数据无非有限数，并记录跨集合重复内容。

有限差分采用

$$g_j^{\text{num}} = \frac{J(\theta + \varepsilon e_j) - J(\theta - \varepsilon e_j)}{2\varepsilon}, \qquad \varepsilon = 10^{-6}.$$

这类核验不是简单重复训练代码，而是从不同计算路径验证关键数学关系。它们能发现梯度少系数 2、截距被惩罚、交互项遗漏等错误；但通过小规模数值检查不等价于证明所有输入上都没有程序问题，还需结合实际任务的输出一致性判断。

8.3 优化误差与泛化误差的区别

多元线性回归实验中 BGD 和闭式解的训练损失几乎相同，说明**优化误差**很小；这并不说明模型已经能准确预测所有葡萄酒质量。最小二乘最优解只是当前线性模型类中的训练最优解，仍有模型表达限制、不可观测因素与样本差异。

学习率实验改变学习率，主要影响达到同一训练最优点的速度和稳定性；岭回归实验改变正则化强度，改变目标本身及其最优解；多项式回归实验改变特征空间，改变模型表达能力。三类操作的作用不同，应分别说明，而不能将任何误差下降都归因于“训练更充分”。

8.4 不同模型的综合结果

表 18: 葡萄酒数据主要模型结果汇总

模型	训练 MSE	测试 MSE	主要观察
BGD 线性回归	0.562708	0.569501	接近闭式解，优化已充分。
普通最小二乘	0.562708	0.569488	当前测试 MSE 最低的 11 维候选。
岭回归 $\lambda = 1$	0.562708	0.569571	权重略收缩，误差未改善。
二阶多项式	0.492450	0.619978	验证集选择，测试存在大残差。
四阶多项式	0.237318	421.428415	训练拟合强，但泛化明显不稳定。

表中模型采用相同的白葡萄酒数据划分，因而其 MSE 具有直接可比性。一元回归的响应尺度不同，其误差单独报告。普通最小二乘在当前测试集上的 MSE 最低，这一排序仍需通过独立数据或重复划分检验。

9 实现细节与误差控制

9.1 数据读取与预处理的一致性

葡萄酒数据采用分号分隔，读取后核对特征矩阵维度、目标列及数值类型。原始数据中的重复样本予以保留，同时分别检查索引交集与记录内容的重合情况。两项检查对应不同层面的样本独立性，应结合解释评估结果。

标准化参数仅由拟合训练集估计，并用于后续验证和预测。内部参数选择与外层重训使用各自的训练统计量，避免预处理阶段引入验证集或测试集信息。多项式模型同时保存原始特征和展开特征的标准化参数，以保持训练与预测变换一致。

9.2 数值求解与目标函数的一致性

正规方程通过求解线性方程组实现，病态或秩不足时采用伪逆；高阶多项式直接使用 SVD 最小二乘。该处理减少了显式求逆及构造正规方程所引入的数值误差，但不改变最小二乘的拟合目标。

梯度下降采用 MSE 目标，对应梯度包含系数 2。若将目标写为半 MSE，同一学习率下的更新幅度将相差一倍。因此，学习率对照以一致的目标函数定义为前提，并通过有限差分核验解析梯度。

岭回归的惩罚矩阵在截距位置取 0。目标整体平移实验表明，响应变量增加常数后仅截距相应变化，特征权重保持不变，支持当前截距处理与理论设定一致。

9.3 模型选择与评价指标的解释

学习率比较同时考察最终训练误差与达到既定阈值的迭代轮数。前者反映固定预算下的优化精度，后者用于区分收敛速度。二次目标的 Hessian 进一步给出稳定步长范围，为实验曲线提供理论参照。

模型阶数与正则化参数根据内部验证误差选择，最终测试结果用于评价所选方案。二阶模型在验证集与测试集上的排序差异，反映了单次划分的不确定性。后续研究可采用训练集内部交叉验证评估这种波动。

误差分析同时保留 MSE、MAE、分位数及极端样本的贡献。四阶模型的大残差对 MSE 有显著影响，反映其样本外预测的不稳定性。不同指标之间的差异应结合误差分布解释，而不宜仅依据单一汇总值评价模型。

10 结论

一元线性回归得到 $\hat{y} = 2.520868x + 6.719009$，训练与测试 MSE 分别为 3.375624 和 3.454386。白葡萄酒多元线性回归采用 BGD 求解，3000 轮后测试 MSE 为 0.569501，与解析解接近，表明当前迭代设置下的优化误差较小。

学习率实验表明，当前标准化矩阵下 0.3 在所比较候选中达到训练阈值最快，1.0 超过稳定上界并发散。岭回归实现了不惩罚截距的闭式解，但本次划分中正则化参数取正值时没有带来验证提升；过大的惩罚导致权重明显收缩和欠拟合。

多项式实验显示，增加模型复杂度可以降低训练误差，却不保证泛化更好。二阶在验证集最优，但测试 MSE 高于一阶；四阶的测试 MSE 达到 421.428415，主要由极少数极端残差驱动。单特征四阶曲线并未出现同等程度的失稳，进一步说明参数规模与特征交互比“阶数”这个数字本身更能反映模型复杂度。

上述结果基于固定随机划分。数据中的重复记录及验证集划分波动限制了结论的外推范围。后续可采用分组划分与交叉验证进一步考察模型稳定性，并对高阶多项式引入正则化以控制参数方差。

参考资料

[1] 课程材料：《实验 2 回归分析实验报告》，包含基础、中级、高级和拓展要求。

[2] 课程代码模板：`task1_framework.py`、`task2_framework_sgd.py`、`task3_framework_sgd_lr.py`、`task4_framework_ridge.py`、`task_ext_poly_framework.py`。

[3] 本地课程数据：`dataset_regression.csv` 与 `winequality-white.csv`。

[4] 本实验运行记录：`outputs/results_all.json`、各任务指标 CSV、测试预测 CSV 及 `verification.json`。

A 运行方法与结果文件

A.1 依赖包与运行方法

实验所需的第三方包为 numpy>=1.24、pandas>=2.0 和 matplotlib>=3.7。安装依赖后即可运行，无需使用特定名称的虚拟环境。以下命令从包含 Lab2/ 的项目根目录执行；进入该目录后，所有路径均相对于 Lab2/：

```
cd Lab2
python -m pip install -r requirements.txt
python run_all.py
python verify_results.py
python report/analyze_results.py
python report/verify_comparison.py
```

单独运行某项实验时，可执行 python run_all.py --task 1，其中参数取值为 1、2、3、4 或 ext。结果统一保存于 outputs/。下节列出的结果文件均相对于该输出目录。

A.2 主要输出文件与读取顺序

1. results_all.json：先查看环境与整体指标，确认解释器和数据 SHA256。
2. task1_metrics.csv、task1_predictions.csv：查看一元回归参数、误差和 5 点预测。
3. task2_metrics.csv、task2_history.csv、task2_weights.csv：查看 BGD 误差、每轮损失和系数。
4. task3_metrics.csv、task3_histories.csv：查看学习率状态与完整曲线数据；历史表行索引从 0 开始，对应第 1 次更新。
5. task4_metrics.csv、task4_weights.csv：查看 8 种正则化参数的误差及主实验 $\lambda = 1$ 权重。
6. task_ext_metrics.csv、task_ext_test_predictions.csv：查看不同阶数结果和逐测试样本预测。
7. report_error_distribution.csv、report_top_errors.csv：查看详细报告补充的误差分布与极端样本诊断。

B 关键实测数值摘录

B.1 一元回归与线性模型

以下数值摘自已保存的实际运行结果，保留较多小数用于复核：

```
Task 1
  train/test = 96 / 24
  w = 2.5208678470900683
  b = 6.719009462122102
  train_mse = 3.375623765290097
  test_mse = 3.4543862278700446
Task 2
  train/test = 3919 / 979
  learning_rate = 0.05
  epochs = 3000
  train_mse = 0.5627079481261213
  test_mse = 0.5695005217461574
  closed_form_train_mse = 0.5627079414881917
```

B.2 多项式与数值核验

```
degree=1, features=11
  validation_mse = 0.576779601506953
  test_mse = 0.5694884856044342
degree=2, features=77
  validation_mse = 0.5224576805579029
  test_mse = 0.619978082492394
degree=4, features=1364
  validation_mse = 10.464699817467212
  test_mse = 421.42841522092885
Numerical checks: passed
wine_rows = 4898
wine_features = 11
wine_missing_values = 0
wine_duplicate_rows = 937
test_rows_identical_to_a_training_row = 286
```