

南開大學

实验报告

机器学习实验三参数估计与非参数估计

姓名：尚文轩

学号：2412456

专业：计算机科学与技术

2026 年 11 月 6 日

GitHub 仓库

https://github.com/ZR-1N/Machine_Learning_NKU

目录

1 摘要 **3**

2 实验概述 **3**

2.1 实验目的与研究问题 3

2.2 实验任务与组织 3

3 数据生成与评价方法 **4**

3.1 两个场景的数据生成 4

3.2 特征尺度与随机性控制 4

3.3 拟合错误率、交叉验证与留出测试 4

3.4 混淆矩阵与结果保存 5

4 基础实验：LRT 与 MAP 分类 **5**

4.1 任务 1：高斯朴素贝叶斯参数估计 5

4.2 MAP 规则的推导与实现 5

4.3 LRT 阈值与对数形式 6

4.4 两场景分类错误率 6

4.5 可选实验：决策边界与数据分布 7

4.6 分析与解释：为什么 LRT 与 MAP 结果相同 7

4.7 分析与解释：低分离度错误率为何上升 8

5 中级实验：高斯核密度估计与分类 **8**

5.1 任务 2：多维高斯核密度公式 8

5.2 数值稳定的对数求和 8

5.3 KDE 与 LRT 分类规则 8

5.4 五折交叉验证与最优带宽 9

5.5 最优带宽重训与错误率 10

5.6 两场景的决策边界 11

5.7 分析与解释：带宽过小或过大的影响 11

5.8 分析与解释：最优带宽与评价局限 12

6 提高实验：k 近邻概率密度估计 **12**

6.1 任务 3：固定质量与可变体积 12

6.2 近邻距离与核心实现 12

6.3 多参数实验：k 取 1、3 和 5 12

6.4 密度热力图与显示范围 13

6.5 固定位置的数值估计 14

6.6 分析与解释：k 如何影响平滑程度 14

6.7 分析与解释：零半径与自身样本问题 14
6.8 分析与解释：密度值与归一化的区别 15

7 拓展实验：贝叶斯规则分类 **15**
7.1 任务 4：保留特征相关性的高斯模型 15
7.2 参数估计与二次判别函数 15
7.3 Cholesky 求解与后验概率 15
7.4 训练与测试分类结果 16
7.5 两种场景的贝叶斯决策边界 16
7.6 分析与解释：特征相关性为何重要 17
7.7 分析与解释：贝叶斯规则与 LRT 的区别 17
7.8 分析与解释：完整协方差模型的局限 17

8 综合讨论 **18**
8.1 混淆矩阵与误分类结构 18
8.2 参数方法与非参数方法的比较 18
8.3 计算代价与实现取舍 18
8.4 结果适用范围与改进方向 19

9 结论 **19**

参考资料 **19**

A 程序运行说明 **19**
A.1 依赖与运行方法 19
A.2 源码与结果文件 20

1 摘要

本实验围绕参数估计、非参数密度估计与贝叶斯决策之间的联系，完成似然率测试规则（LRT）、最大后验概率规则（MAP）、高斯核密度分类、k 近邻密度估计及完整协方差高斯贝叶斯分类。使用相同设置生成高、低分离度两组二维数据，每组 500 个样本。LRT 与 MAP 在相同估计模型下预测完全一致，两场景的全数据拟合错误率分别为 0.010 和 0.264。高斯核分类经五折交叉验证，在给定候选中均选择带宽 0.1，重训后拟合错误率分别为 0 和 0.068。kNN 密度估计显示，较小的 k 容易产生局部尖峰，增大 k 后局部估计趋于平滑。在固定 70% 训练、30% 测试划分上，完整协方差高斯模型的测试错误率分别为 0.020 和 0.100。实验分别报告全数据拟合、交叉验证和留出测试结果，分析模型假设、平滑参数与评价方法对分类性能的影响。

关键词：参数估计；核密度估计；k 近邻密度；似然率测试；贝叶斯分类

2 实验概述

2.1 实验目的与研究问题

本实验首先从有标签样本估计类别先验与类条件分布，再利用估计结果构造分类决策；随后取消单一高斯分布假设，利用核函数和近邻距离描述样本分布。研究重点包括以下问题：同一模型下 LRT 与 MAP 为何等价；核带宽如何影响分类；近邻数如何影响局部密度；特征相关性如何影响高斯分类模型。

分类与密度估计的输出不同。前者将观测映射为离散类别，后者为查询位置输出相对于特征空间体积的密度值。密度不是某一点的概率，也不需要小于 1。任务 3 估计的是不使用标签的整体分布，不能用分类错误率代替其输出。

2.2 实验任务与组织

表 1：实验任务及对应实现

阶段	任务内容	实验结果
基础实验	高斯参数估计及 LRT、MAP 决策	两场景错误率、参数表、规则等价验证及可选决策边界图
中级实验	高斯核密度分类与五折带宽选择	5 组带宽的逐折结果、最优带宽重训错误率及决策边界
提高实验	无标签 kNN 密度估计	k=1、3、5 的密度网格、热力图及局部密度统计
拓展实验	贝叶斯规则分类	两场景决策边界、训练和测试错误率及协方差对照

核心密度估计与分类算法使用 NumPy 实现，Scikit-learn 用于数据生成、训练测试划分和交叉验证索引构造，Matplotlib 用于绘制决策边界与密度分布。

3 数据生成与评价方法

3.1 两个场景的数据生成

调用 `make_classification`，固定样本数 500、特征数 2、有效特征数 2、冗余特征数 0、类别数 2、每类簇数 1、随机种子 42。高分离度场景取 `class_sep=2.0`，低分离度场景取 0.5。未显式改动的生成器参数保持当前版本默认值，其中 `flip_y=0.01` 表示随机替换标签的机制，并不意味着恰有 1% 的最终标签被翻转。

四项任务使用相同的两组数据，每组 500 个样本。各方法采用一致的样本顺序与随机设置，以控制样本量和数据生成差异对比较结果的影响。

表 2: 两组数据的类别与留出划分

场景	样本数	类别 0/1	训练 0/1	测试 0/1
高分离度	500	249/251	174/176	75/75
低分离度	500	249/251	174/176	75/75

两组数据的类别数均为 249 和 251，先验接近均衡。高、低分离度改变的是生成场景的几何关系，不能将两组数据理解为同一组特征简单缩放后的结果。保存的 `data/high.csv` 和 `data/low.csv` 可直接核对每条记录；数据文件的 SHA256 与软件版本一并保存于运行结果。

3.2 特征尺度与随机性控制

使用生成数据的原始二维特征，不额外标准化。这样候选带宽 0.1、0.5、1、1.5 和 2 均作用于课程数据的原始欧氏距离。若后续对特征进行缩放，带宽与密度单位也随之改变，需要重新选择参数，不能直接沿用本次结果。

固定生成种子和划分种子均为 42，所有方法使用相同样本顺序。任务 2 的五折验证使用 `KFold(n_splits=5, shuffle=True, random_state=42)`，每个候选带宽使用相同的五折划分。由于每折验证样本数均为 100，折错误率平均值等于 500 条折外预测的总体错误率。

3.3 拟合错误率、交叉验证与留出测试

分类错误率定义为

$$\widehat{R} = \frac{1}{m}\sum_{i=1}^{m} \mathbf{1}\{\widehat{y}_i \neq y_i\}.$$

任务 1 在全数据上估计参数并计算同一数据上的分类错误率。任务 2 先在全数据上进行五折验证选择带宽，再用全部数据重训并计算错误率。以上结果属于全数据拟合评价，不能直接解释为独立测试性能。

样本外评价使用 `train_test_split`，设置 `test_size=0.3` 和 `random_state=42`，得到 350 条训练记录、150 条测试记录，不添加分层参数。训练集类别数为 174 和 176，测试集恰为 75 和 75。

核分类的留出实验在 350 条训练数据内部重新做五折验证，每折 280 条拟合、70 条验证，选择带宽后用 350 条数据重训，仅在最后对 150 条测试数据预测。全数据验证选出的带宽不直接用于该留出实验，避免将测试标签通过带宽选择带入训练过程。

3.4 混淆矩阵与结果保存

定义混淆矩阵 C_{ij} 为真实类别为 i、预测为 j 的记录数。本实验同时保留错误数、样本数与错误率，以便核查分母。预测 CSV 保留原始零基行号，可将任何误分类记录追溯到对应数据文件。

主结果见 `outputs/results_all.json` 与 `outputs/metrics.csv`；逐折验证见 `outputs/task2_cv.csv`；kNN 密度网格与统计另行保存。图像用于观察边界和局部结构，数值结论以未裁剪的结果文件为准。

4 基础实验：LRT 与 MAP 分类

4.1 任务 1：高斯朴素贝叶斯参数估计

对每个类别分别估计先验、均值及总体方差。设类别 c 的样本数为 N_c，总样本数为 N，则

$$\widehat{\pi}_c = \frac{N_c}{N}, \qquad \widehat{\mu}_{cj} = \frac{1}{N_c}\sum_{i:y_i=c} x_{ij}, \qquad \widehat{\sigma}^2_{cj} = \frac{1}{N_c}\sum_{i:y_i=c}(x_{ij}-\widehat{\mu}_{cj})^2.$$

方差分母为 N_c，对应高斯模型的极大似然估计。任务 1 采用特征条件独立假设，将类条件联合密度写成各维高斯密度的乘积。计算时加上 10^{-9} 的方差正则项，避免退化特征导致除零。

表 3: 任务 1 的高斯朴素贝叶斯参数

场景	类别	$\hat{\pi}_c$	$\hat{\mu}_{c1}$	$\hat{\mu}_{c2}$	$\hat{\sigma}^2_{c1}$	$\hat{\sigma}^2_{c2}$
高分离度	0	0.498000	2.002426	-2.018743	0.766587	1.666446
高分离度	1	0.502000	2.040853	2.007641	0.798104	0.404244
低分离度	0	0.498000	0.502426	-0.518743	0.766587	1.666446
低分离度	1	0.502000	0.540853	0.519594	0.798104	0.328377

两组数据的先验均为 0.498 和 0.502。低分离度场景两个类别的第二维均值更接近，而方差不为零，因此观测范围重叠更明显。是否可以通过其他特征关系进一步分类，还取决于联合分布结构，不能只比较每一维的均值。

4.2 MAP 规则的推导与实现

贝叶斯公式给出

$$P(C_c \mid x) = \frac{p(x \mid C_c)P(C_c)}{\sum_r p(x \mid C_r)P(C_r)}.$$

对给定观测 x，分母与候选类别无关，因此 MAP 决策为

$$\widehat{c}_{\mathrm{MAP}} = \arg\max_c \{\log p(x \mid C_c) + \log \widehat{\pi}_c\}.$$

这里的 MAP 指类别后验最大化的决策规则，均值与方差仍通过样本极大似然估计得到；它不是对模型参数另行施加先验后的 MAP 参数估计。

对角协方差高斯的对数似然为

$$\ell_c(x) = -\frac{1}{2}\sum_{j=1}^{d}\left[\log\{2\pi(\widehat{\sigma}^2_{cj}+\epsilon)\} + \frac{(x_j-\widehat{\mu}_{cj})^2}{\widehat{\sigma}^2_{cj}+\epsilon}\right].$$

直接计算该式，避免先计算极小概率密度再取对数所造成的下溢。将已下溢的密度任意替换为固定常数，会改变远离训练区域时的相对似然，本实现不采用这种替代。

Listing 1: MAP 分类的核心计算

```
log_like = model._calculate_log_likelihood(X)
log_joint = log_like + np.log(model.priors_)
predictions = model.classes_[np.argmax(log_joint, axis=1)]
```

4.3 LRT 阈值与对数形式

二分类、误分类代价相同的条件下，选择类别 1 当且仅当

$$\Lambda(x) = \frac{p(x \mid C_1)}{p(x \mid C_0)} > \frac{P(C_0)}{P(C_1)}.$$

转为对数形式，有

$$\ell_1(x) - \ell_0(x) > \log \widehat{\pi}_0 - \log \widehat{\pi}_1.$$

本次阈值为 $\log(249/251) = -0.008000043$，接近但不等于 0。若先验不相等仍将阈值固定为 1（对数阈值为 0），对应的规则会忽略类别先验。

Listing 2: 与 MAP 使用同一估计模型的 LRT 规则

```
log_like = model._calculate_log_likelihood(X)
log_ratio = log_like[:, 1] - log_like[:, 0]
threshold = np.log(model.priors_[0]) - np.log(model.priors_[1])
predictions = model.classes_[(log_ratio > threshold).astype(int)]
```

4.4 两场景分类错误率

表 4: LRT 与 MAP 全数据拟合结果

场景	MAP 错误数	MAP 错误率	LRT 错误率	预测不一致数
高分离度	5	0.010000	0.010000	0
低分离度	132	0.264000	0.264000	0

高分离度下共有 5 条误分类，低分离度下共有 132 条误分类，两种规则均得到相同结果。两组原始数据上的不一致预测数均为 0；在每组 170 乘 170 的可视化查询网格上，不一致数也为 0。

将先验加到对数似然后比较大小，与将似然差和先验阈值比较，属于同一判别式的两种代数写法。该结果验证的是在相同估计分布、先验和代价下的规则等价，并不意味着高斯朴素贝叶斯已经恢复真实数据分布。

4.5 可选实验：决策边界与数据分布

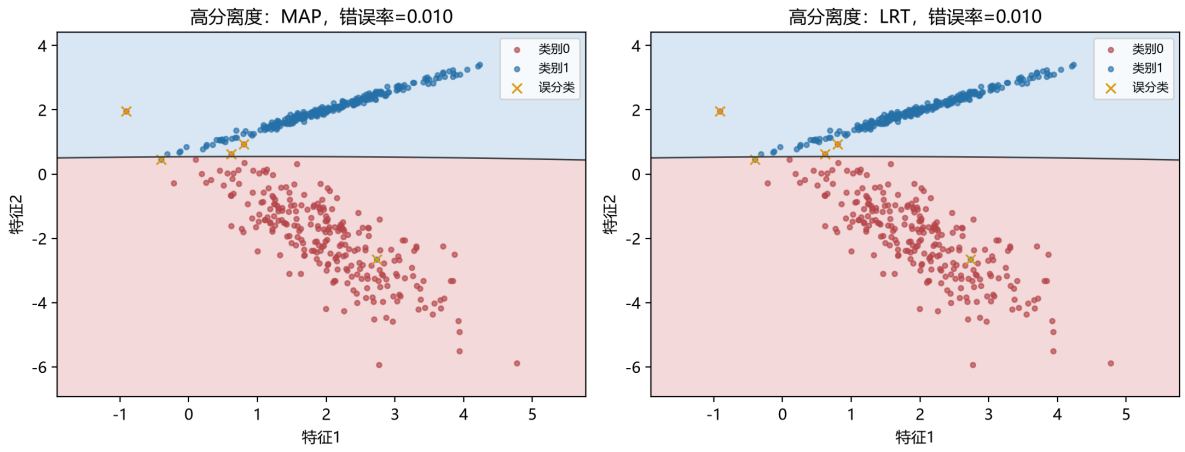


图 1：高分离度数据的 MAP 与 LRT 决策区域；黄色叉号标记全数据拟合中的错误样本

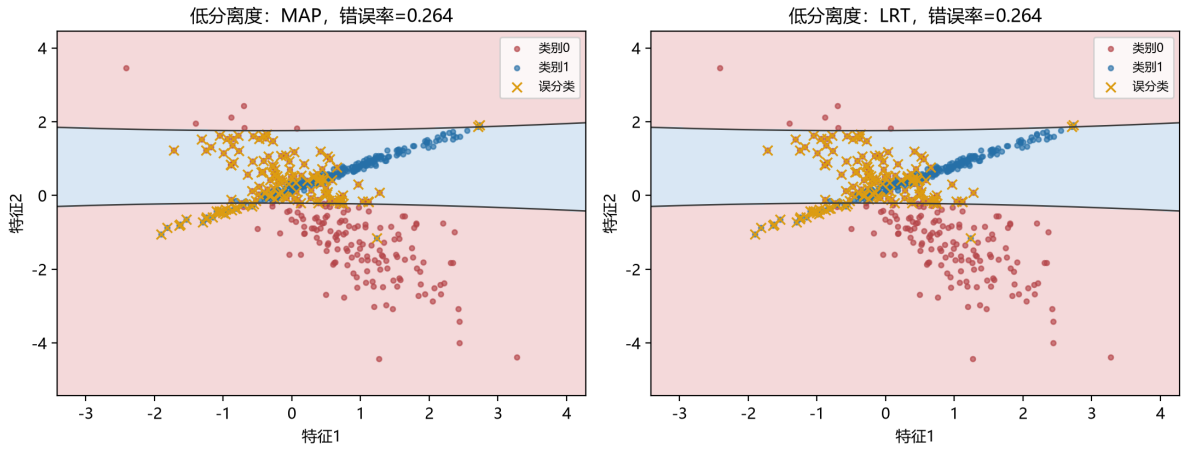


图 2：低分离度数据的 MAP 与 LRT 决策区域；两种规则在同一模型下边界重合

背景颜色表示预测类别，灰色曲线表示判别函数为 0 的位置。边界由全数据估计模型得到；图中的错误标记亦使用该全数据拟合口径。由于两个类别分别估计方差，决策函数一般含二次项，边界不必是一条直线。

4.6 分析与解释：为什么 LRT 与 MAP 结果相同

对正密度，将 MAP 的比较式 $p(x \mid C_1)\pi_1 > p(x \mid C_0)\pi_0$ 两侧同时除以 $p(x \mid C_0)\pi_1$，即可得到 LRT 形式。对数变换保持大小关系。因此在二分类且代价一致时，阈值取先验比的 LRT 与 MAP 完全等价。

当两边恰好相等时，MAP 的 `argmax` 返回第一个类别；LRT 使用严格大于号，也在相等时返回第一个类别。统一平局规则可以避免边界上出现实现层面的不一致。若改成不等误分类代价，阈值应相应调整，最大后验决策不再自动对应最小期望代价。

4.7 分析与解释：低分离度错误率为何上升

低分离度场景类间重叠增加，使同一位置附近出现不同标签的概率增大；与此同时，对角协方差模型忽略了两个特征的类内相关关系。因此错误率上升既可能来自分布本身的重叠，也可能来自模型结构过于受限。后续完整协方差实验用于检验第二种因素。

高分离度也不能保证错误数为 0。数据生成含随机标签机制，有限样本参数估计和高斯独立假设还会带来误差。当前结果只说明在这组固定样本上更易分类，不能把 1% 解释为真实分布的不可降低误差下界。

5 中级实验：高斯核密度估计与分类

5.1 任务 2：多维高斯核密度公式

对类别 c 的 N_c 个样本，使用各向同性高斯核估计类条件密度：

$$\widehat{p}_h(x \mid C_c) = \frac{1}{N_c h^d (2\pi)^{d/2}} \sum_{i:y_i=c} \exp\left(-\frac{\|x - x_i\|^2}{2h^2}\right).$$

其中 $d = 2$，h 是原始特征空间的带宽。带宽固定，样本在局部区域的贡献随距离平滑衰减，不要求类条件分布只有一个高斯峰。

核密度公式中的 N_c、h^d 与高斯常数共同保证密度的归一化。在两类维度与带宽相同的分类比较中，$h^d(2\pi)^{d/2}$ 可以抵消；但类别样本数一般不同，N_c 不能任意省略。若再乘经验先验 N_c/N，则可化为该类核和除以共同常数 $Nh^d(2\pi)^{d/2}$，这与先分别估计归一化类密度再加入先验一致。

5.2 数值稳定的对数求和

记 $a_i = -\|x - x_i\|^2/(2h^2)$，$m = \max_i a_i$，则

$$\log \sum_i e^{a_i} = m + \log \sum_i e^{a_i - m}.$$

因此不必先将所有高斯核变成可能下溢的密度数值，也无需在核和为 0 时加入任意常数。分批处理查询点，每批最多 512 条，控制网格预测时的内存使用。

Listing 3: 归一化高斯核密度的稳定计算

```
diff = (query[:, None, :] - train[None, :, :]) / h
log_kernel = -0.5 * np.sum(diff * diff, axis=2)
m = log_kernel.max(axis=1)
log_sum = m + np.log(np.exp(log_kernel - m[:, None]).sum(axis=1))
log_density = log_sum - np.log(N) - d*np.log(h) - d/2*np.log(2*np.pi)
```

5.3 KDE 与 LRT 分类规则

分别对两个类别的训练样本拟合核密度估计器，得到 $\widehat{p}_h(x \mid C_0)$ 和 $\widehat{p}_h(x \mid C_1)$。按照任务 1 相同的先验比阈值进行 LRT 分类：

$$\widehat{c} = \mathbf{1}\left\{\log \widehat{p}_h(x \mid C_1) - \log \widehat{p}_h(x \mid C_0) > \log \widehat{\pi}_0 - \log \widehat{\pi}_1\right\}.$$

在交叉验证中，类别先验、两类样本集合均只来自当前拟合折。验证标签仅用于计算错误率，不参与密度估计。

5.4 五折交叉验证与最优带宽

候选带宽严格采用说明中的

$$\mathcal{H} = \{0.1, 0.5, 1, 1.5, 2\}.$$

对于每个候选，使用相同五组训练/验证索引，计算各折错误率并取平均，以平均错误率最小者为最优。若出现完全相同的平均值，保留候选列表中最先出现的带宽；本次全数据选择不存在并列最优。

表 5: 五折交叉验证：各候选带宽的分类错误率

场景	h	平均错误率	折间标准差	累计错误数
高分离度	0.1	0.008000	0.008367	4
高分离度	0.5	0.010000	0.007071	5
高分离度	1	0.014000	0.008944	7
高分离度	1.5	0.024000	0.016733	12
高分离度	2	0.028000	0.014832	14
低分离度	0.1	0.078000	0.008367	39
低分离度	0.5	0.164000	0.028810	82
低分离度	1	0.224000	0.042190	112
低分离度	1.5	0.266000	0.038471	133
低分离度	2	0.290000	0.047958	145

表 6: 全数据带宽 0.1 的逐折验证结果

场景	第 1 折	第 2 折	第 3 折	第 4 折	第 5 折
高分离度	0.000000	0.000000	0.010000	0.020000	0.010000
低分离度	0.080000	0.080000	0.070000	0.090000	0.070000

表中标准差为五个折错误率的样本标准差，描述不同折之间的波动，不是总体泛化错误率的置信区间。高分离度带宽 0.1 和 0.5 的累计验证错误分别为 4 和 5，仅相差 1 条；不能据此宣称二者的真实预测能力存在显著差异。

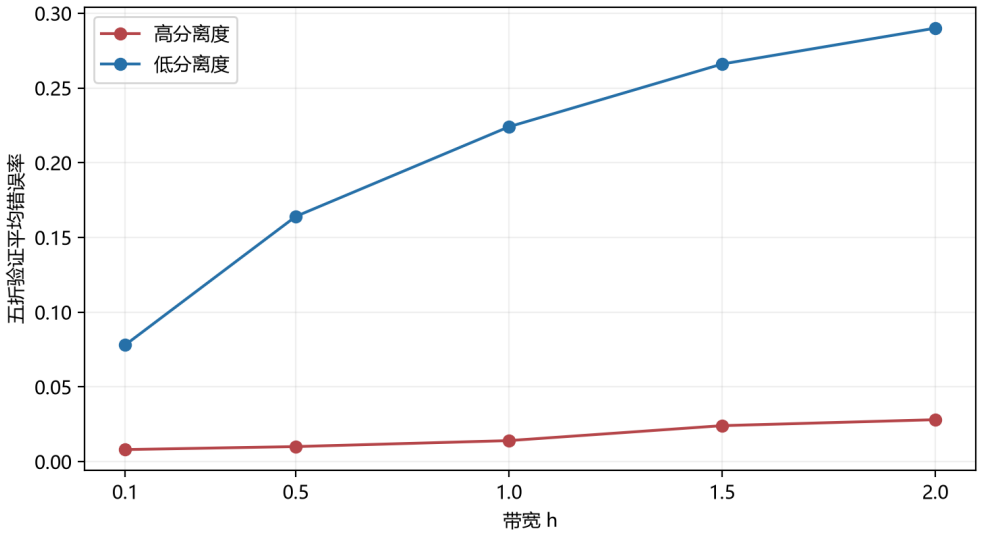


图 3: 给定五组带宽的五折验证平均错误率，所有候选使用同一折划分

5.5 最优带宽重训与错误率

表 7: 核密度分类的拟合与留出测试结果

场景	全数据最优 h	拟合错误率	训练集 CV 最优 h	测试错误率
高分离度	0.1	0.000000	0.5	0.013333
低分离度	0.1	0.068000	0.1	0.086667

在全数据验证协议下，两场景均选择 $h = 0.1$。重训后高分离度错误数为 0，低分离度错误数为 34，对应拟合错误率 0 和 0.068。这些样本同时用于估计密度，尤其较小带宽时，样本自身的核会提高其所属类别在该点的估计密度，因此拟合误差通常偏乐观。

另行执行的留出协议中，高分离度在 350 条训练记录内选择 $h = 0.5$，测试错误数为 2；低分离度仍选择 0.1，测试错误数为 13。两种协议使用的带宽选择数据不同，出现不同最优值并非计算矛盾。

5.6 两场景的决策边界

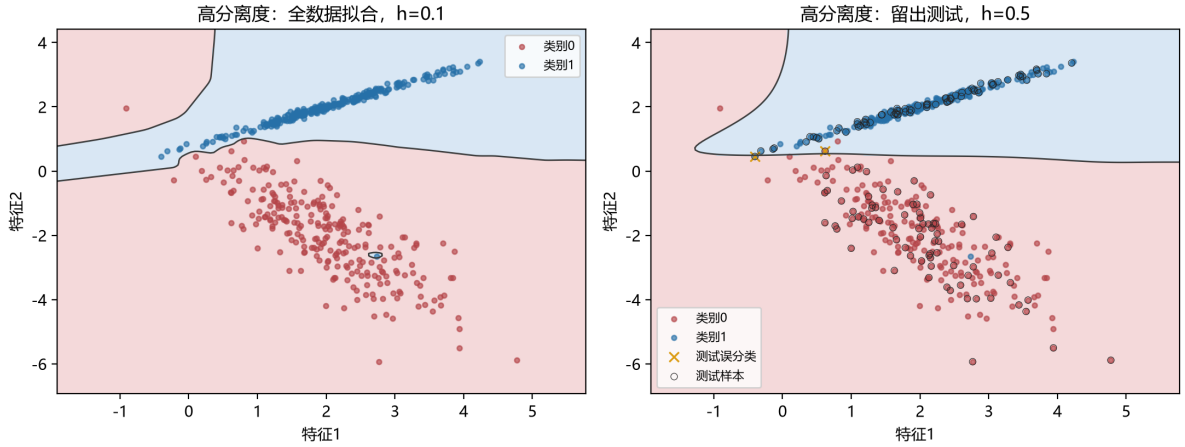


图 4: 高分离度核密度分类：左为全数据重训，右为仅使用训练集选择带宽的留出实验

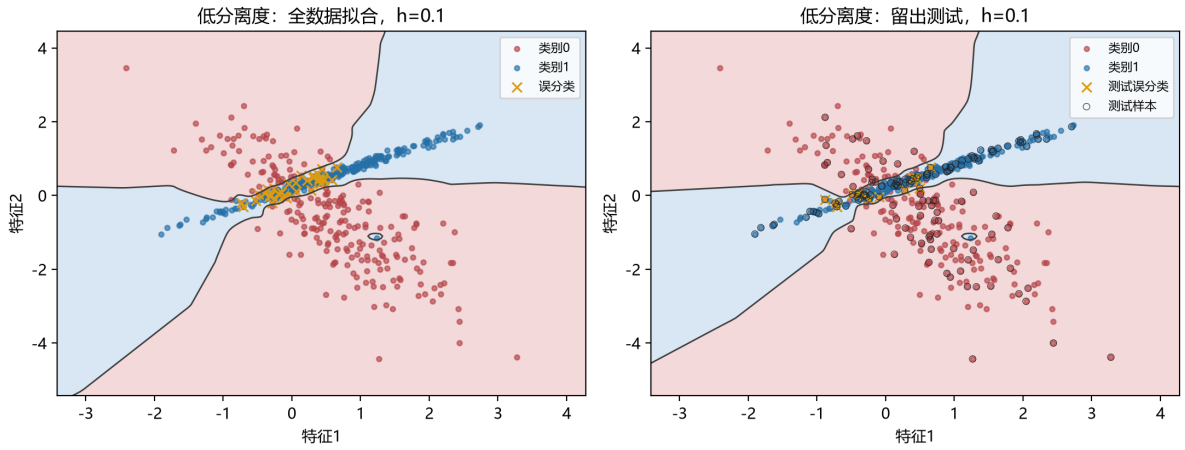


图 5: 低分离度核密度分类：曲线表示后验比较相等的位置，右图空心圆标记测试样本

核方法的决策区域可随数据局部结构弯曲，比任务 1 的高斯独立模型更灵活。远离样本的区域仍会被分配类别，但该区域数据支持稀少，不能仅由大面积背景颜色推断模型在那里有充分证据。

5.7 分析与解释：带宽过小或过大的影响

带宽越小，单个核的影响区域越窄，模型对局部样本变化越敏感，可能产生碎片化边界与较大的估计方差。带宽增大后，相邻核贡献被平均，边界更平滑，但可能抹去区分类别的重要局部结构，引入偏差。

本次低分离度场景的验证错误率从 $h = 0.1$ 时的 0.078 升至 $h = 2$ 时的 0.290，表明候选范围内过度平滑使分类信息明显丢失。高分离度的对应错误率为 0.008 和 0.028，变化较小，说明较明显的类间间隔使模型对平滑更宽容。

5.8 分析与解释：最优带宽与评价局限

两个场景在全数据五折验证中均以 0.1 最优，但它同时位于候选区间下端。本实验可以得出“给定候选中 0.1 最好”，不能据此断言在全部正实数带宽中 0.1 最优。更细的带宽搜索属于后续工作，不替换课程规定的候选实验。

用五折验证结果选择参数后，再将其中最小值当作完全独立的最终误差，仍会受到参数选择影响。因此报告另外给出未参与带宽选择的测试结果。一次 150 条测试样本的结果也存在随机波动，不宜对只相差一两条错误的模型作过强排序结论。

6 提高实验：k 近邻概率密度估计

6.1 任务 3：固定质量与可变体积

kNN 密度估计不预先固定核宽度，而是在查询点周围扩展邻域，直到包含 k 个训练样本。记第 k 近邻距离为 $r_k(x)$，在二维欧氏空间中圆形邻域面积为

$$V_2(r_k) = \pi r_k^2, \qquad \boxed{\widehat{p}_k(x) = \frac{k}{N\pi r_k(x)^2}.}$$

其解释是用邻域内样本比例 k/N 除以对应面积。样本密集时，达到 k 个邻居所需半径小，密度较大；稀疏区域半径大，估计密度较小。此处不进行多数投票，也不读取类别标签。

一般维度下单位球体积为 $v_d = \pi^{d/2}/\Gamma(d/2+1)$，估计式为 $k/(Nv_d r_k^d)$。实现支持该通式，但课程实验和所有绘图均为二维。

6.2 近邻距离与核心实现

对每个查询位置计算到全部 500 条特征记录的平方距离，通过 `np.partition` 找到第 k 个顺序统计量，而不必对全部距离完整排序。这样仍执行精确近邻查询，不近似省略远处样本。

Listing 4: kNN 局部密度的核心实现

```
dist2 = np.sum((query[:, None, :] - train[None, :, :])**2, axis=2)
r2 = np.partition(dist2, k-1, axis=1)[:, k-1]
volume = np.pi * r2
density = np.divide(float(k), N*volume,
                    out=np.full_like(r2, np.inf), where=volume > 0)
```

合法参数应为整数且满足 $1 \le k \le N$。分批计算查询点，减少二维网格展开后的临时数组内存。所有主实验网格密度均保留为 CSV，可从中核对任意位置的半径相关结果。

6.3 多参数实验：k 取 1、3 和 5

每组数据在两维样本范围外各延伸 1 个单位，构造 160 乘 160 的固定查询网格，共 25600 个位置。在同一场景中，三个 k 使用完全相同的查询位置。除了整幅热力图，额外报告中位数、上分位数与最大值，区分普遍变化与少量尖峰。

表 8: 固定网格上的 kNN 密度分布

场景	k	中位数	95% 分位	99% 分位	最大值
高分离度	1	0.000728	0.128226	1.016957	465.617748
高分离度	3	0.001156	0.078056	0.292875	4.766476
高分离度	5	0.001578	0.071538	0.236200	4.487789
低分离度	1	0.000869	0.140681	1.118192	13149.157664
低分离度	3	0.001155	0.081331	0.333212	9.049647
低分离度	5	0.001509	0.073665	0.292624	5.628598

高分离度的网格最大值从 $k = 1$ 时约 465.62 降至 $k = 3$ 时 4.77 及 $k = 5$ 时 4.49；低分离度对应约 13149.16、9.05 和 5.63。这些最大值对网格位置敏感，不能把它们解释为连续空间密度的全局最大值。

6.4 密度热力图与显示范围

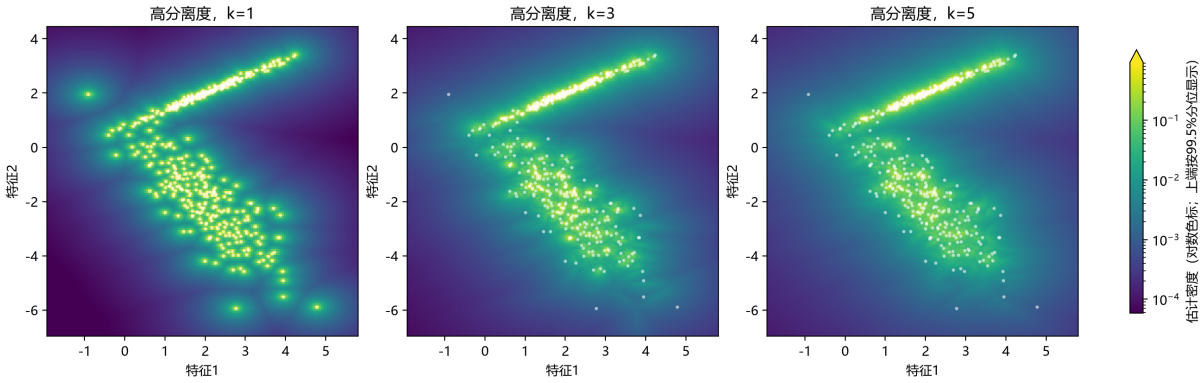


图 6: 高分离度的 kNN 密度估计；同一场景三个 k 共用对数色标，白点为不带标签的训练位置

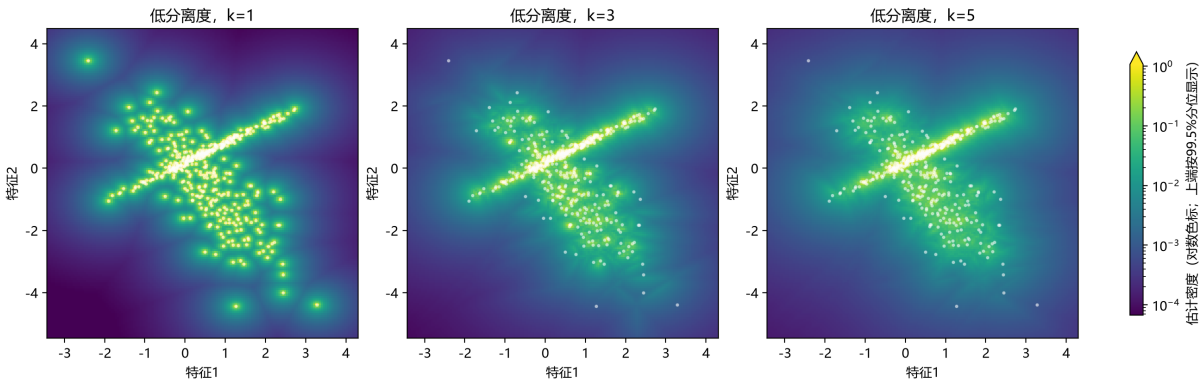


图 7: 低分离度的 kNN 密度估计；增加 k 主要降低极小邻域所造成的尖峰

为避免极少数尖峰压缩其余区域的颜色差异，色标上端取该场景三个 k 全部网格密度的 99.5% 分位，下端取 1% 分位。超出显示范围的密度保持原值，仅使用端点颜色显示；表格与 CSV 未裁剪。两个场景分别确定色标，因此不应跨图仅凭相同颜色判断密度相等。

6.5 固定位置的数值估计

表 9: 固定查询位置的 kNN 密度估计

场景	点号	x_1	x_2	k=1	k=3	k=5
高分离度	0	0.000000	0.000000	0.017693	0.014185	0.014758
高分离度	1	2.021716	0.002502	0.006020	0.007181	0.009369
低分离度	0	0.000000	0.000000	0.162279	0.208409	0.320859
低分离度	1	0.521716	0.002502	0.513980	0.196232	0.095505

点号 0 为原点，点号 1 为该组全部特征的样本均值。它们仅是用于演示密度输出的查询位置，不带类别标签。固定位置上的估计不必随 k 单调下降，因为 k 增加时分子增大，而第 k 近邻面积也发生变化，二者共同决定最终比值。

6.6 分析与解释：k 如何影响平滑程度

较小 k 使用很小的局部邻域，能够突出细节，但第一个近邻距离的微小变化就可能造成很大密度差异；较大 k 通过包含更多邻居降低这种局部波动，同时可能掩盖狭窄结构。样本密度不均匀时，邻域半径自动变化，这是 kNN 估计相对固定带宽核估计的重要差别。

本次 $k = 3$ 和 5 相比 1 的极端网格值明显降低，支持局部平滑增强的观察。但仅凭 $k = 5$ 更平滑，不能断言它已经欠拟合；本实验未给出真实生成密度，无法直接计算积分平方误差来确定最佳 k。三个候选均按要求计算并保留，不以视觉偏好代替定量选参。

6.7 分析与解释：零半径与自身样本问题

如果查询位置恰好等于某条训练记录，当 $k = 1$ 时第一个距离为 0，估计式理论上发散。程序返回正无穷，明确保留零体积的含义；不将其替换为任意有限大数后再作为有效结果解释。可视化网格与训练坐标通常不完全重合，本次网格输出均为有限值。

另作逐点排除自身的诊断：在查询第 i 条训练记录时，按索引只排除该记录，再从其余 499 条记录中寻找邻居，并用 499 作为有效样本数。该处理不会把其他同坐标记录一并删除，也不用于替换主实验的网格密度。

表 10: 逐点排除自身后的局部密度诊断

场景	k	中位数	95% 分位	最大值
高分离度	1	0.265027	8.760144	203.941631
高分离度	3	0.168107	1.780056	4.113507
高分离度	5	0.137192	1.419751	5.148321
低分离度	1	0.305661	9.478686	203.941631
低分离度	3	0.193185	1.988623	6.975782
低分离度	5	0.182813	1.565962	5.148321

排除自身后仍可见 $k = 1$ 的高分位值远大于较大 k，说明尖峰不只是把自身误算成近邻造成的，也来自真实局部近邻距离非常小。不同 k 的最大值不必严格单调，不能将“总体更平滑”理解成每个查询点上的单调性。

6.8 分析与解释：密度值与归一化的区别

连续变量的密度值可以大于 1，只有对区域积分才对应概率。另一方面，有限样本的朴素 $k/(NV)$ 近邻估计在整个无界空间上不一定可积为 1：远离有限样本时，r_k 与到原点距离同阶，估计尾部近似 r^{-d}，结合球壳体积 $r^{d-1}\,dr$ 会产生对数发散。

因此，本任务按课程公式解释局部密度，未将有限网格值再强制归一化，也不对其作“全空间积分等于 1”的校验。高斯 KDE 每个核本身归一化，有限混合仍积分为 1；这两类估计器在有限样本下的归一化性质不能混为一谈。

7 拓展实验：贝叶斯规则分类

7.1 任务 4：保留特征相关性的高斯模型

使用与前述任务相同的数据，划分为 350 条训练记录、150 条测试记录。在每类内部拟合完整协方差高斯分布，按后验概率最大化进行预测，同时用对角协方差模型作对照。

任务 1 已完成高斯朴素贝叶斯；这里保留非对角协方差，直接考察特征相关信息对分类的影响。完整协方差模型增加了参数自由度，但仍属于参数估计方法，每个类别由固定维数的均值向量与协方差矩阵描述。

7.2 参数估计与二次判别函数

类内协方差的极大似然估计为

$$\widehat{\Sigma}_c = \frac{1}{N_c} \sum_{i:y_i=c} (x_i - \widehat{\mu}_c)(x_i - \widehat{\mu}_c)^T + \epsilon I.$$

加入 $\epsilon = 10^{-9}$ 的对角正则以支持数值求解。判别函数为

$$g_c(x) = \log \widehat{\pi}_c - \frac{1}{2} \log |\widehat{\Sigma}_c| - \frac{1}{2}(x - \widehat{\mu}_c)^T \widehat{\Sigma}_c^{-1} (x - \widehat{\mu}_c).$$

省略了所有类别共有的 $-d \log(2\pi)/2$。各类别协方差独立估计，因此通常得到二次决策边界。若强制所有类别使用同一协方差，二次项在比较中抵消，才会得到线性边界；本实验未施加该共享约束。

7.3 Cholesky 求解与后验概率

对正定协方差分解 $\widehat{\Sigma}_c = L_c L_c^T$，求解 $L_c z = x - \widehat{\mu}_c$，则二次型等于 $z^T z$，对数行列式等于 $2\sum_j \log(L_c)_{jj}$。该方式不显式计算逆矩阵。

Listing 5: 完整协方差高斯对数密度

```
L = np.linalg.cholesky(covariance)
z = np.linalg.solve(L, (X - mean).T)
log_det = 2 * np.log(np.diag(L)).sum()
log_like = -0.5 * (d*np.log(2*np.pi) + log_det + (z*z).sum(axis=0))
```

需要输出概率时，在对数联合概率上减去每行最大值，再进行指数化与归一化。这样两个类别的后验和为 1，也避免将未归一化的对数联合分数误称为后验概率。

表 11: 任务 4 完整协方差模型的训练参数

场景	类别	μ_1	μ_2	Σ_{11}	Σ_{12}	Σ_{22}
高分离度	0	1.996172	-1.973993	0.775027	-0.896675	1.595891
高分离度	1	2.056842	2.005588	0.651344	0.388804	0.384338
低分离度	0	0.496172	-0.473993	0.775027	-0.896675	1.595891
低分离度	1	0.556842	0.522633	0.651344	0.400364	0.276124

完整模型和对角模型使用相同的训练样本、均值和先验，区别仅在于是否保留非对角项。两个类别的训练先验分别为 174/350 和 176/350，测试集标签不用于修正这些先验。

7.4 训练与测试分类结果

表 12: 贝叶斯分类：相同留出划分下的比较

场景	模型	训练错误率	测试错误率	测试错误数
高分离度	完整协方差	0.005714	0.020000	3
高分离度	对角协方差	0.008571	0.026667	4
低分离度	完整协方差	0.080000	0.100000	15
低分离度	对角协方差	0.242857	0.306667	46

高分离度完整模型测试错误 3 条，对角模型 4 条；低分离度分别为 15 条和 46 条。在相同测试样本上，低分离度完整模型比对角模型少错 31 条，表明保留相关结构对当前数据有明显作用。高分离度只相差 1 条，不能据此对两者作普遍优劣判断。

完整模型在低分离度下的训练错误率 0.080、测试错误率 0.100，均显著低于对角模型的 0.242857 和 0.306667。这种训练和测试同时改善的现象，与简单增加参数后只改善训练误差的情形不同，更支持原独立性假设遗漏重要结构的解释。

7.5 两种场景的贝叶斯决策边界

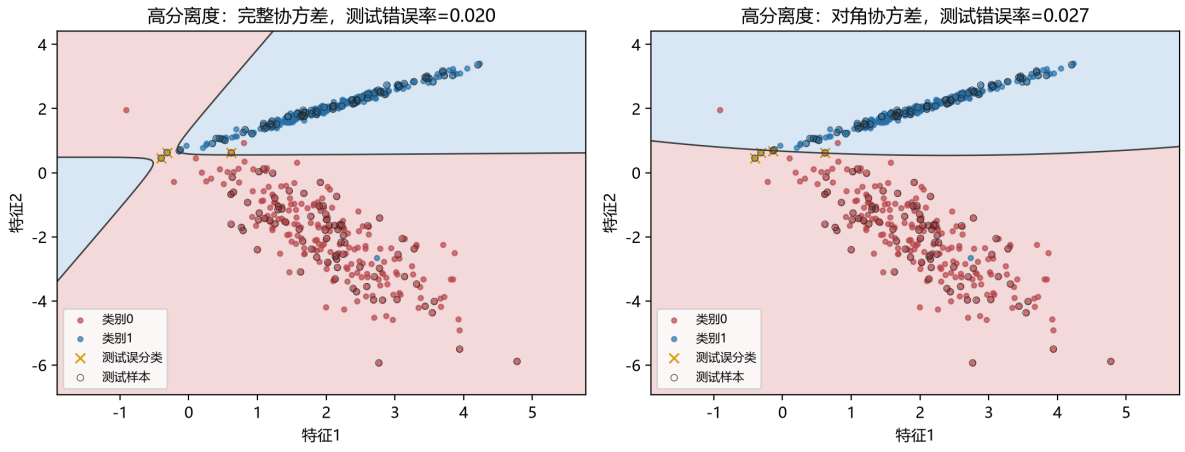


图 8: 高分离度的贝叶斯分类；两模型均只使用 350 条训练数据估计参数，空心圆标记测试记录

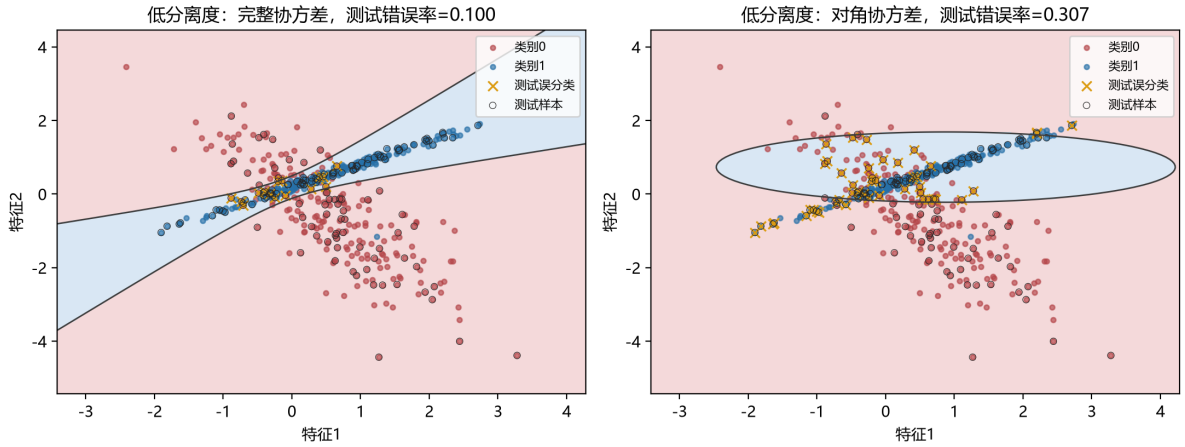


图 9: 低分离度的贝叶斯分类；完整协方差模型可利用类内倾斜结构，黄色叉号只标记测试错误

边界估计只来自训练集，图中同时展示全部样本位置用于观察分布，其中测试样本用空心外圈区分。图示中的测试坐标不参与参数拟合，测试标签仅用于错误标记与评价。

7.6 分析与解释：特征相关性为何重要

表 13: 按类别计算的原始特征相关系数

场景	类别 0	类别 1
高分离度	-0.796062	0.855109
低分离度	-0.796062	0.964968

两个类别的相关系数绝对值均较高，低分离度类别 1 更达到约 0.965。若将联合密度强制写为两维边缘密度乘积，就会把沿斜线分布的窄带扩展成与坐标轴对齐的区域，丢失组合特征的判别信息。

完整协方差中的非对角项刻画这种类内相关性，使密度等高线能够沿数据主要方向倾斜。低分离度下，类间间隔较小，相关结构提供的额外信息更关键；高分离度时，仅凭第二维位置已有较强区分能力，因此增加相关信息的收益较小。

7.7 分析与解释：贝叶斯规则与 LRT 的区别

贝叶斯公式描述先验、似然与后验之间的关系；MAP 以最大后验为决策准则；LRT 将二分类决策写成似然比与阈值的比较。它们并不要求使用不同的密度估计器。

任务 1 与任务 4 的模型表现不同，来自对角和完整协方差这两种类条件分布假设，以及评价数据范围不同，而不是因为一种使用 LRT、另一种使用贝叶斯公式。对任务 4 完整模型重新应用含先验阈值的 LRT，两个测试集上的预测不一致数均为 0。

7.8 分析与解释：完整协方差模型的局限

完整高斯模型虽然利用了相关关系，仍假定每一类可由单个椭圆型分布描述。带有非高斯结构、多个子簇或异常标签的数据可能偏离这一假设。二维样本量足以支持当前协方差估计，但在高维小

样本条件下，完整协方差参数数目快速增长，通常需要更强正则或结构约束。

核分类在当前低分离度测试集上错误 13 条，完整高斯模型 15 条，只相差 2 条。该结果可作为当前划分的观察，不能据一次测试声称核方法始终优于完整协方差贝叶斯模型。

8 综合讨论

8.1 混淆矩阵与误分类结构

表 14: 主要模型的混淆矩阵分量（真实类别为行，预测类别为列）

场景	方法	范围	C_{00}	C_{01}	C_{10}	C_{11}
高分离度	任务 1 MAP	全数据	246	3	2	249
高分离度	任务 2 KDE	全数据	249	0	0	251
高分离度	任务 4 完整协方差	测试集	74	1	2	73
低分离度	任务 1 MAP	全数据	143	106	26	225
低分离度	任务 2 KDE	全数据	215	34	0	251
低分离度	任务 4 完整协方差	测试集	60	15	0	75

低分离度任务 1 将 106 条类别 0 记录判为 1、26 条类别 1 记录判为 0，错误存在方向性。核分类全数据重训错误 34 条，均为类别 0 判成 1。任务 4 完整模型的测试错误 15 条也均为类别 0 判成 1。类别计数接近平衡，不能将这种现象简单归因于严重的类别不均衡，还需要结合分布形状与局部重叠解释。

上述混淆矩阵包含不同评价范围，表中明确标为全数据或测试集。不能将任务 1 的全数据错误率与任务 4 的测试错误率直接相减，并将差额完全解释为方法改进。对角模型在相同 350/150 划分上的测试结果已给出，才是与完整模型的直接对照。

8.2 参数方法与非参数方法的比较

高斯分类将每一类压缩为均值、协方差和先验，预测代价较低，解释明确，但分布结构受限。核方法在预测时保留训练样本贡献，能够表达更细的局部结构，但需要选择带宽，计算和存储成本随样本量增长。

kNN 密度与 KDE 都使用距离描述局部分布。KDE 固定带宽、通过样本在邻域内的贡献改变估计质量；kNN 固定邻居数、通过邻域体积随位置变化获得局部适应性。任务 3 估计整体密度，而任务 2 按类别估计条件密度；二者不能仅凭图像相似就视为同一个目标。

8.3 计算代价与实现取舍

设训练样本数为 N、查询数为 M、维度为 d。高斯模型拟合后每个类别只保留固定参数；完整协方差预测需处理二次型。直接 KDE 和精确 kNN 查询的距离计算约为 $O(MNd)$，本实验采用分批查询以控制内存，不改变估计公式。

kNN 通过分区选择第 k 距离，避免每个查询都做完整排序。对于更大的数据，可以采用空间树或其他近邻索引；在当前二维 500 样本规模下，直接距离计算便于核查，运行成本也足以满足实验要求。

8.4 结果适用范围与改进方向

结论基于固定随机种子与单次留出划分。生成器带有标签随机机制，低分离度的数据结构也不能由单一指标完全描述。后续可重复多个随机种子或使用重复交叉验证，考察带宽和模型排序的稳定性。

进一步研究可比较自适应带宽、正则化协方差或高斯混合模型，但这些方法未替代本次指定任务。kNN 最佳 k 的选择需额外给出密度误差准则或适当的验证目标，不能从 k=1、3、5 的热力图直接推出统计最优值。

9 结论

本实验比较了两个分离度场景下的高斯参数模型、核密度分类与 k 近邻密度估计。LRT 与 MAP 在相同先验和类条件密度下给出一致分类，说明规则差异不应与模型假设差异混淆。高斯核分类在给定候选中选择 0.1，低分离度的全数据拟合错误率由对角高斯模型的 0.264 降至 0.068，但其拟合误差与留出误差需要分别解释。

kNN 密度估计随 k 增大总体减少局部尖峰，零半径与训练点自身查询需要明确处理。完整协方差高斯分类利用了强类内相关结构，低分离度留出测试错误率为 0.100，低于同一划分的对角模型 0.306667。实验说明，密度估计结构、平滑参数及评价协议共同影响最终分类结果。

参考资料

[1] 课程实验说明：《实验三参数估计与非参数估计》。

[2] 课程演示材料：《实验三参数估计与非参数估计》。

[3] 课程代码模板：LRT 与 MAP、高斯核密度与 LRT、kNN 密度估计、贝叶斯分类四个 Python 文件。

A 程序运行说明

A.1 依赖与运行方法

程序使用 NumPy、Matplotlib 和 Scikit-learn，依赖版本见 `requirements.txt`。从包含 `lab3/` 的项目根目录执行：

```
cd lab3
python -m pip install -r requirements.txt
python run_all.py
```

运行单项实验可执行 `python run_all.py --task 1`，其中任务号取 1、2、3 或 4。也可分别运行 `task1.py` 至 `task4.py`。程序将生成数据保存到 `data/`，将指标、预测与图像保存到 `outputs/`。

A.2 源码与结果文件

表 15: 主要程序与实验输出，路径相对于 lab3 目录

文件或目录	内容
`density_core.py`	高斯分类模型、MAP/LRT、高斯核密度及 kNN 密度估计
`run_all.py`	数据生成、交叉验证、分类评估与图像输出
`task1.py` 至 `task4.py`	四项实验的独立运行入口
`data/`	两组数据与训练测试划分索引
`outputs/results_all.json`	数据设置、模型参数与汇总指标
`outputs/metrics.csv`	分类错误数、评价样本数与错误率
`outputs/task2_cv.csv`	各候选带宽的逐折验证结果
`outputs/task3_statistics.csv`	不同 k 下的密度分位数与极值
`outputs/task4_parameters.csv`	贝叶斯模型的均值、协方差与先验